

Dédicaces

Je dédie ce modeste travail

*À mon père,
source inépuisable de force et de sagesse,
dont le soutien indéfectible m'a porté tout au long de ce chemin.*

*À ma mère,
pour son amour inconditionnel, sa tendresse et ses prières
qui ont illuminé chacune de mes journées.*

*À ma chère sœur **Eya**,
pour sa complicité, son encouragement constant
et les moments de joie partagés.*

*À mes amis,
pour leur présence, leur bonne humeur et leur précieux soutien
tout au long de cette aventure.*

*À toutes les personnes qui m'ont encouragé et aidé
durant mon stage de fin d'études,
et qui ont contribué, de près ou de loin,
à la réussite de ce projet.*

Remerciements

Après avoir rendu grâce à **Dieu**, le Tout-Puissant et le Miséricordieux, qui m'a accordé la volonté, la patience et la santé nécessaires pour mener à bien ce projet de fin d'études.

Je tiens à exprimer ma profonde gratitude à mon encadrant académique, **Mr. Mohamed Islem Samaali**, pour ses conseils avisés, sa disponibilité permanente et ses orientations scientifiques qui ont été déterminantes pour structurer ma démarche et enrichir mes réflexions tout au long de ce travail.

Mes sincères remerciements s'adressent également à mes encadrants en entreprise, **Mr. Slim** et **Madame Hajer**, pour leur accueil chaleureux, la confiance qu'ils m'ont accordée et les précieuses orientations métier qui m'ont permis de mieux appréhender les enjeux réels de la détection d'anomalies financières.

Je remercie tout particulièrement **Madame Emna Zanni**, responsable du département Audit IT, pour son soutien, sa bienveillance et les ressources qu'elle a mises à ma disposition, contribuant ainsi de manière significative à la réussite de ce projet.

Enfin, je remercie chaleureusement mes **camarades de stage** pour les échanges enrichissants, la bonne ambiance et l'entraide qui ont rendu cette expérience encore plus formatrice et agréable.

Résumé

Ce projet de fin d'études s'inscrit dans le contexte croissant de digitalisation des services financiers, où les établissements doivent traiter un volume toujours plus important de transactions tout en faisant face à des tentatives de fraude de plus en plus sophistiquées. Réalisé au sein de **PwC Tunisie**, ce travail vise à concevoir une plateforme complète de détection d'anomalies financières capable d'assister les auditeurs dans l'identification rapide et fiable de comportements suspects.

Le projet suit la méthodologie **CRISP-DM** et s'appuie sur un jeu de données d'environ 200 000 transactions, dont une proportion infime est frauduleuse. Ce déséquilibre extrême constitue l'un des principaux défis et a nécessité l'utilisation de techniques adaptées telles que la pondération des classes, le rééchantillonnage et des métriques d'évaluation centrées sur le rappel et le F1-score.

Plusieurs approches ont été explorées, notamment des modèles supervisés (régression logistique, forêt aléatoire, XGBoost) et un **autoencoder** non supervisé entraîné sur les transactions légitimes. Une couche d'explicabilité a été intégrée à l'aide de **SHAP**, **LIME** et d'un modèle de langage permettant de générer des explications compréhensibles pour les équipes métier.

Le projet aboutit à une solution modulaire, reproductible et intégrée dans une architecture technique moderne combinant FastAPI, PostgreSQL et une interface web développée en Next.js. Cette plateforme offre aux auditeurs un outil fiable pour analyser les transactions, comprendre les décisions des modèles et générer des rapports professionnels.

Mots-clés : détection d'anomalies, fraude financière, CRISP-DM, autoencoder, XGBoost, SHAP, LIME, explicabilité, PwC Tunisie.

Abstract

This final-year project addresses the growing need for intelligent fraud detection in a financial ecosystem where institutions must process increasingly large volumes of transactions while facing more sophisticated fraudulent behaviors. Conducted within **PwC Tunisia**, the project aims to design a complete anomaly detection platform to support auditors in identifying suspicious patterns efficiently and reliably.

Following the **CRISP-DM** methodology, the work is based on a dataset of nearly 200,000 transactions, with only a very small fraction labeled as fraudulent. This severe class imbalance represents a major challenge and required the use of adapted strategies such as class weighting, oversampling techniques, and evaluation metrics focused on recall and F1-score.

Several modeling approaches were explored, including supervised models (logistic regression, random forest, XGBoost) and a deep **autoencoder** trained exclusively on legitimate transactions. To enhance transparency, an explainability layer was integrated using **SHAP**, **LIME**, and a language model capable of generating human-readable explanations for business users.

The project results in a modular and reproducible solution deployed within a modern technical architecture combining FastAPI, PostgreSQL, and a Next.js web interface. The platform provides auditors with a reliable tool to analyze transactions, interpret model outputs, and generate professional reports.

Keywords : anomaly detection, financial fraud, CRISP-DM, autoencoder, XGBoost, SHAP, LIME, explainability, PwC Tunisia.

Introduction générale

La digitalisation accélérée des services financiers a profondément transformé la manière dont les institutions traitent et sécurisent les transactions. Chaque jour, des volumes massifs d'opérations circulent entre banques et plateformes de paiement, créant un environnement où la rapidité doit s'accompagner d'une vigilance constante. Dans ce contexte, les schémas frauduleux évoluent rapidement et deviennent difficiles à détecter à l'aide de mécanismes traditionnels fondés sur des règles statiques.

Cette évolution place les métiers de l'audit face à un défi majeur : identifier plus tôt les comportements suspects, comprendre les signaux faibles et fournir des analyses fiables aux équipes métier. L'intelligence artificielle, et en particulier l'apprentissage automatique, offre aujourd'hui des outils capables d'extraire des patterns complexes et de repérer des anomalies dans de vastes ensembles de données.

C'est dans cette dynamique que s'inscrit ce projet de fin d'études réalisé au sein de **PwC Tunisie**. L'objectif est de concevoir une **plateforme complète de détection d'anomalies financières**, combinant modèles de machine learning, outils d'explicabilité et interface destinée aux auditeurs. Au-delà de la performance, la solution vise à être **compréhensible, fiable et adaptée aux besoins opérationnels** d'un cabinet d'audit international.

Deux enjeux ont guidé la conception du système : la **rareté des cas frauduleux**, qui nécessite des stratégies de modélisation spécifiques, et la **transparence des prédictions**, indispensable dans un contexte réglementaire exigeant. La méthodologie **CRISP-DM** a structuré l'ensemble du travail, depuis la compréhension métier jusqu'au déploiement technique.

Ce rapport présente ainsi les différentes étapes du projet : analyse du besoin, étude et préparation des données, construction des modèles, intégration des mécanismes d'explicabilité, puis mise en place d'une architecture technique moderne et reproductible. L'ensemble aboutit à une solution cohérente, robuste et alignée avec les attentes de PwC Tunisie et des professionnels de l'audit.

Table des matières

Dédicaces	1
Remerciements	2
Résumé	3
Abstract	4
Introduction générale	5
Liste des figures	12
Liste des tableaux	13
Liste des abréviations	14
1 Contexte général et organisme d'accueil	15
1.1 Introduction	15
1.2 Présentation de PwC International	15
1.2.1 Historique et positionnement mondial	15
1.2.2 PwC dans le Big Four	16
1.2.3 Fiche signalétique	17
1.2.4 Statut juridique	18
1.2.5 Une entreprise en perpétuelle évolution	18
1.2.6 Les valeurs de PwC	19
1.3 PwC Tunisie	19
1.3.1 Présentation générale	19
1.3.2 Fiche signalétique de PwC Tunisie	19
1.3.3 Offres de services de PwC Tunisie	20
1.3.4 Vue d'ensemble des lignes de services	20
1.3.5 Références clients	21
1.4 Cadre du projet de fin d'études	21
1.4.1 Contexte du projet de fin d'études	21

1.4.2	Problématique	21
1.4.3	Objectifs du projet	22
1.4.4	Critères de succès	22
1.5	Méthodologie CRISP-DM	23
1.5.1	Présentation et justification du choix	23
1.5.2	Comparaison avec les autres méthodologies	24
1.5.3	Application au projet	24
1.6	Conclusion du chapitre	24
2	Analyse et spécification des besoins	26
2.1	Introduction	26
2.2	Contexte métier : la fraude dans l’audit financier	26
2.2.1	Définition et typologies de la fraude	26
2.2.2	Enjeux économiques et réglementaires	27
2.2.3	Limites des systèmes à base de règles	27
2.3	Identification des acteurs du système	27
2.3.1	Introduction	27
2.3.2	Acteurs principaux et responsabilités	28
2.3.3	Rôles et matrice d’accès (RBAC)	28
2.4	Cas d’utilisation	29
2.4.1	Diagramme général des cas d’utilisation	29
2.4.2	Description détaillée des cas principaux	29
2.4.3	Diagrammes de séquence	32
2.5	Modèle de données du domaine	34
2.5.1	Diagramme général des classes	34
2.5.2	Diagrammes de classes détaillés	34
2.5.3	Entités principales	37
2.6	Backlog produit et planification agile	37
2.6.1	Introduction	37
2.6.2	User stories prioritaires	37
2.6.3	Planification en sprints	38
2.7	Architecture fonctionnelle	38
2.8	Conclusion du chapitre	39
3	Compréhension et préparation des données	40
3.1	Introduction	40
3.2	Présentation du jeu de données	40

3.2.1	Origine et description du simulateur	40
3.2.2	Description des variables brutes	41
3.2.3	Qualité et bilan des données	41
3.3	Analyse exploratoire des données (EDA)	42
3.3.1	Déséquilibre des classes	42
3.3.2	Distribution des montants et types de transactions	42
3.3.3	Analyse temporelle et comportementale	43
3.3.4	Analyse des soldes et détection de leakage	43
3.3.5	Baseline de la règle métier existante	43
3.4	Pipeline de préparation des données	44
3.4.1	Suppression des variables à risque de leakage	44
3.4.2	Ingénierie de variables	44
3.4.3	Ensemble final de variables	45
3.4.4	Division stratifiée	45
3.4.5	Normalisation	45
3.5	Gestion du déséquilibre de classes	46
3.5.1	Pondération des classes	46
3.5.2	SMOTE	46
3.5.3	Ensemble dédié à l’autoencoder	47
3.6	Mapping sémantique automatique des colonnes	47
3.6.1	Problématique des schémas non standards	47
3.7	Conclusion du chapitre	48
4	Modélisation et évaluation	49
4.1	Introduction	49
4.2	État de l’art des approches de détection	49
4.2.1	Approches supervisées	49
4.2.2	Approches non supervisées	50
4.2.3	Justification des modèles retenus	50
4.3	Modèles supervisés	50
4.3.1	Régression logistique	51
4.3.2	Forêt aléatoire	51
4.3.3	XGBoost	51
4.3.4	Optimisation des seuils de décision	52
4.4	Modèles non supervisés	52
4.4.1	Autoencoder	52

4.4.2	Détermination du seuil MSE optimal	53
4.4.3	Isolation Forest	53
4.4.4	Visualisation de l'espace latent	53
4.5	Métriques d'évaluation	54
4.5.1	Choix et justification	54
4.5.2	Résultats comparatifs sur l'ensemble de test	54
4.5.3	Analyse des matrices de confusion	54
4.6	Interprétabilité des modèles (XAI)	55
4.6.1	Méthode SHAP	55
4.6.2	Méthode LIME	56
4.6.3	Comparaison SHAP vs LIME	56
4.6.4	Explicabilité par LLM (Groq / Gemini)	57
4.7	Sélection du modèle de production	57
4.8	Conclusion du chapitre	58
5	Déploiement et architecture technique	59
5.1	Introduction	59
5.2	Architecture générale de la plateforme	59
5.2.1	Vue d'ensemble	59
5.2.2	Justification des choix technologiques	59
5.2.3	Modes de prédiction	60
5.3	Backend FastAPI	60
5.3.1	Structure des routes et endpoints REST	61
5.3.2	Pipeline de prédiction asynchrone	61
5.3.3	Services principaux	62
5.3.4	Système de cache LRU et gestion du cycle de vie	62
5.4	Modèle de données PostgreSQL	62
5.4.1	Schéma de base de données	62
5.4.2	Migrations Alembic	63
5.5	Frontend Next.js 15	64
5.5.1	Architecture App Router	64
5.5.2	Wizard d'analyse en 3 étapes	64
5.5.3	Gestion de l'état et des données (Prisma ORM)	64
5.6	Sécurité et authentification	65
5.6.1	Flux d'authentification JWT	65
5.6.2	Contrôle d'accès par rôle (RBAC)	65

5.6.3	Journal d’audit immuable	66
5.7	Génération de rapports	66
5.7.1	Rapport PDF	66
5.7.2	Rapport Word	67
5.8	Conteneurisation Docker	67
5.8.1	Structure docker-compose	67
5.8.2	Orchestration et reproductibilité	68
5.9	Tests unitaires et couverture	68
5.10	Conclusion du chapitre	68
6	Interfaces, résultats et perspectives	70
6.1	Introduction	70
6.2	Interfaces de la plateforme	70
6.2.1	Page d’authentification	70
6.2.2	Tableau de bord principal	71
6.2.3	Gestion des missions d’audit	72
6.2.4	Wizard d’analyse	72
6.2.5	Interface d’explication multicouche	74
6.2.6	Génération et téléchargement du rapport	75
6.2.7	Journal d’audit	75
6.3	Résultats de validation fonctionnelle	75
6.3.1	Performances sur le jeu de test de référence	75
6.3.2	Robustesse au schéma non standard	76
6.3.3	Difficultés rencontrées et solutions apportées	76
6.4	Bilan du projet	77
6.4.1	Objectifs atteints	77
6.4.2	Contributions techniques	77
6.4.3	Limites identifiées	78
6.5	Perspectives d’amélioration	78
6.5.1	Pipeline MLOps complet	79
6.5.2	Intégration RAG et LLM avancé	79
6.5.3	Conformité et gouvernance IA	79
6.5.4	Améliorations métier	80
6.6	Conclusion générale	80
	Bibliographie	81

A	Hyperparamètres détaillés des modèles	81
A.1	Hyperparamètres complets de la régression logistique	81
A.2	Hyperparamètres complets de la forêt aléatoire	81
A.3	Hyperparamètres complets de l'XGBoost	82
A.4	Hyperparamètres complets de l'autoencodeur	82
B	Statistiques et entraînement des modèles	84
B.1	Statistiques descriptives du jeu de données	84
B.2	Évolution de l'entraînement de l'Autoencoder	84
B.3	Importances des features et corrélations	85
C	Extraits de code source	86
C.1	Architecture de l'AutoEncoder PyTorch	86
C.2	Détection automatique du mode de prédiction	87
C.3	Mapping sémantique des colonnes	88

Table des figures

1.1	Logo officiel de PwC	15
1.2	Présence mondiale du réseau PwC	16
1.3	Les quatre grands cabinets d’audit mondiaux (Big Four)	17
1.4	Organigramme simplifié de PwC Tunisie	20
1.5	Secteurs clients de PwC Tunisie	21
1.6	Cycle CRISP-DM	23
2.1	Vue Générale de diagramme de Cas d’Utilisation	29
2.2	Importation et préparation des données	29
2.3	Lancement de l’analyse de détection	30
2.4	Consultation des résultats et explications	30
2.5	Validation des alertes	31
2.6	Génération de rapport d’audit	32
2.7	Importation et validation des données	33
2.8	Diagramme de classes général	34
2.9	Diagramme de classes général	35
2.10	Diagramme de classes : ML Pipeline + Models + Services	36
2.11	Diagramme de classes : API + Frontend Layer	36
6.1	Interface de connexion de la plateforme PwC SmartAudit	71
6.2	Tableau de bord principal de la plateforme	71
6.3	Page de gestion des missions d’audit	72
6.4	Sélection du jeu de données	73
6.5	Exécution du pipeline	73
6.6	Tableau de bord des résultats d’analyse	74
6.7	Interface d’explication multicouche d’une transaction suspecte	74
6.8	Interface de génération et téléchargement du rapport	75
6.9	Journal d’audit - traçabilité complète des actions	75
C.1	Architecture de l’AutoEncoder implémenté avec PyTorch	86
C.2	Détection automatique du mode de prédiction	87
C.3	Exemple de mapping sémantique des colonnes	88

Liste des tableaux

3.1	Description des variables brutes du jeu de données	41
4.1	Comparaison des modèles sur le jeu de test	55
4.2	Matrice de confusion - XGB_smote (seuil = 0.355)	55
5.1	Justification des choix technologiques de la plateforme	60
5.2	Groupe de routes de l'API REST	61
5.3	Matrice d'accès par rôle utilisateur	66
6.1	Résultats de validation fonctionnelle sur le jeu de test de référence . . .	76
6.2	Résultats du mapping sémantique sur schémas non standards	76
6.3	Bilan de réalisation des objectifs du projet	77
A.1	Hyperparamètres de la régression logistique	81
A.2	Hyperparamètres du Random Forest	81
A.3	Hyperparamètres de XGBoost	82
A.4	Hyperparamètres de l'autoencodeur	83
B.1	Statistiques descriptives des variables numériques (200 000 transactions)	84
B.2	Courbe de perte de l'Autoencoder (sélection d'époques, seed = 42) . . .	84
B.3	Top-10 des importances du modèle Random Forest et corrélations avec la cible	85

Liste des abréviations

AE	AutoEncoder
AUC	Area Under the Curve
BN	Batch Normalization
CRISP-DM	Cross-Industry Standard Process for Data Mining
EDA	Exploratory Data Analysis (Analyse Exploratoire des Données)
ERP	Enterprise Resource Planning (Progiciel de Gestion Intégré)
F1	F1-Score
LLM	Large Language Model (Grand Modèle de Langage)
LIME	Local Interpretable Model-agnostic Explanations
LR	Logistic Regression (Régression Logistique)
ML	Machine Learning (Apprentissage Automatique)
MSE	Mean Squared Error (Erreur Quadratique Moyenne)
ONG	Organisation Non Gouvernementale
PR-AUC	Area Under the Precision-Recall Curve
RF	Random Forest (Forêt Aléatoire)
ROC	Receiver Operating Characteristic
RCM	Risk & Control Matrix (Matrice de Risques et de Contrôles)
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
XAI	Explainable Artificial Intelligence

1. Contexte général et organisme d'accueil

1.1 Introduction

Le projet présenté dans ce rapport s'inscrit dans un contexte où les organisations, et en particulier les institutions financières, évoluent dans un environnement marqué par une digitalisation rapide et une complexité croissante des risques. Les volumes de données augmentent, les processus se modernisent et les attentes en matière de transparence, de conformité et de sécurité deviennent plus exigeantes. Dans ce paysage en constante mutation, les métiers de l'audit jouent un rôle essentiel pour accompagner les entreprises, renforcer la confiance et anticiper les menaces émergentes, notamment celles liées à la fraude financière.

Ce premier chapitre vise à situer le cadre général du projet en présentant l'organisme d'accueil, **PwC**, un acteur mondialement reconnu dans les domaines de l'audit, du conseil et des services professionnels. Il met en lumière son positionnement international, ses valeurs, ainsi que les spécificités de son implantation en Tunisie. Cette contextualisation permet de comprendre l'environnement dans lequel le projet a été réalisé et les motivations qui ont conduit à la mise en place d'une solution technologique dédiée à la détection d'anomalies financières.

Le chapitre introduit également le cadre du stage de fin d'études, les enjeux auxquels répond le projet, ainsi que les objectifs fixés. Enfin, il présente la méthodologie **CRISP-DM**, choisie pour structurer l'ensemble du travail, et qui constitue le fil conducteur des différentes étapes décrites dans les chapitres suivants.

1.2 Présentation de PwC International

1.2.1 Historique et positionnement mondial



FIGURE 1.1 – Logo officiel de PwC

PwC fait partie des acteurs les plus influents du secteur de l’audit et du conseil. Son histoire est le résultat d’un long héritage professionnel qui remonte au XIX^e siècle. Deux cabinets indépendants, Price Waterhouse et Coopers & Lybrand, ont progressivement bâti leur réputation grâce à leur expertise comptable et à leur rôle dans la structuration des pratiques modernes d’audit. Leur fusion en 1998 a donné naissance à PricewaterhouseCoopers, une entité unifiée qui adoptera en 2010 l’appellation simplifiée **PwC**, aujourd’hui reconnue dans le monde entier.

Au fil des décennies, le réseau s’est étendu pour devenir l’un des leaders mondiaux des services professionnels. Présent dans plus de 150 pays et regroupant plusieurs centaines de milliers de collaborateurs, PwC accompagne aussi bien les grandes multinationales que les organisations publiques, les PME et les entreprises émergentes. Cette présence internationale lui permet de combiner une vision globale des enjeux économiques avec une compréhension fine des réalités locales.

La force du réseau repose sur sa capacité à anticiper les transformations du marché, à intégrer les nouvelles technologies et à proposer des solutions adaptées aux défis contemporains : digitalisation, cybersécurité, conformité réglementaire, gestion des risques ou encore transition durable. Grâce à cette dynamique d’innovation continue, PwC s’impose comme un partenaire stratégique pour les organisations souhaitant renforcer leur performance, leur transparence et leur résilience.




FIGURE 1.2 – Présence mondiale du réseau PwC

1.2.2 PwC dans le Big Four

PwC fait partie du groupe restreint des « Big Four », un terme qui désigne les quatre plus grands réseaux mondiaux spécialisés dans l’audit, la fiscalité, le conseil et les services professionnels. Aux côtés de Deloitte, EY et KPMG, PwC occupe une place stratégique dans un secteur où la crédibilité, la rigueur méthodologique et la capacité à accompagner les organisations dans leurs transformations sont essentielles.

L’appartenance au Big Four confère à PwC une reconnaissance internationale fondée sur plusieurs éléments : la qualité de ses travaux d’audit, la diversité de ses expertises,

la solidité de son réseau mondial et sa capacité à intervenir sur des problématiques complexes touchant aussi bien les entreprises privées que les institutions publiques. Cette position lui permet d’être un acteur clé dans l’évolution des normes comptables, des pratiques de gouvernance et des exigences réglementaires.

Au-delà de son rôle historique dans l’audit financier, PwC s’est progressivement imposé comme un partenaire de référence dans des domaines en pleine expansion tels que la cybersécurité, la transformation digitale, l’analyse de données ou encore la gestion des risques. Cette polyvalence, combinée à une présence internationale étendue, renforce son influence au sein du Big Four et lui permet d’accompagner ses clients dans un environnement économique en constante mutation.




FIGURE 1.3 – Les quatre grands cabinets d’audit mondiaux (Big Four)

1.2.3 Fiche signalétique

PwC est un réseau mondial de cabinets indépendants opérant sous une même marque et partageant des standards communs en matière de qualité, d’éthique et de méthodologie. Son organisation repose sur une structure fédérée qui lui permet d’allier cohérence internationale et adaptation aux spécificités locales de chaque marché.

- **Dénomination** : PricewaterhouseCoopers (PwC)
- **Nature** : Réseau international de cabinets d’audit, de conseil et de services professionnels
- **Année de création** : 1998 (fusion de Price Waterhouse et Coopers & Lybrand)
- **Rebranding** : Adoption du nom simplifié « PwC » en 2010
- **Présence géographique** : Plus de 150 pays
- **Effectif mondial** : Plusieurs centaines de milliers de collaborateurs
- **Domaines d’activité** : Audit, fiscalité, conseil en management, transactions, cybersécurité, transformation digitale, gestion des risques
- **Clientèle** : Multinationales, PME, institutions publiques, organisations internationales, start-up

Cette fiche signalétique reflète la diversité et l’ampleur du réseau PwC, dont la force réside dans sa capacité à mobiliser des expertises variées et à intervenir sur des problématiques complexes, tout en maintenant un haut niveau d’exigence et de qualité.

1.2.4 Statut juridique

PwC n'est pas une entreprise unique mais un **réseau international** composé de cabinets juridiquement indépendants, regroupés sous une même marque et engagés à respecter des standards communs de qualité, d'éthique et de gouvernance. Chaque entité nationale possède sa propre personnalité juridique et opère conformément aux réglementations locales, tout en bénéficiant de l'appui méthodologique, technologique et organisationnel du réseau mondial. Cette structure fédérée permet à PwC de concilier deux exigences essentielles : d'une part, garantir une cohérence globale dans les pratiques professionnelles, et d'autre part, offrir une grande flexibilité pour s'adapter aux spécificités économiques, légales et culturelles de chaque pays. Le réseau est coordonné par *PricewaterhouseCoopers International Limited* (PwCIL), une société de droit britannique chargée de définir les orientations stratégiques, les normes de qualité et les principes de gouvernance. Ainsi, bien que les cabinets membres soient autonomes dans leur gestion, ils partagent une identité commune, des méthodologies harmonisées et un engagement collectif envers la transparence, l'intégrité et la création de valeur pour leurs clients.

1.2.5 Une entreprise en perpétuelle évolution

Depuis sa création, PwC s'est construit autour d'une dynamique d'adaptation continue. L'évolution rapide des marchés, l'émergence de nouveaux risques et la transformation digitale des organisations ont conduit le réseau à repenser régulièrement ses méthodes, ses outils et ses domaines d'intervention. Cette capacité à se renouveler constitue l'un des piliers de sa longévité et de son positionnement parmi les leaders mondiaux du secteur. Au-delà de ses missions traditionnelles d'audit et de conseil, PwC a progressivement investi des domaines à forte valeur ajoutée tels que la cybersécurité, l'analyse avancée de données, la transformation digitale, la durabilité ou encore l'intelligence artificielle. Cette diversification lui permet d'accompagner ses clients dans des environnements de plus en plus complexes, où les enjeux technologiques et réglementaires sont étroitement liés. L'entreprise accorde également une importance particulière au développement des compétences de ses collaborateurs. Programmes de formation, certifications, mobilité internationale et culture d'apprentissage continu constituent des leviers essentiels pour maintenir un haut niveau d'expertise. Cette stratégie d'investissement humain, combinée à une volonté d'innovation permanente, permet à PwC de rester un acteur agile, capable d'anticiper les mutations du marché et d'offrir des solutions adaptées aux défis contemporains.

1.2.6 Les valeurs de PwC

Les valeurs de PwC constituent le fondement de son identité et guident l'ensemble de ses actions à travers le monde. Fidèle à sa raison d'être, « construire la confiance et résoudre des enjeux importants », le réseau encourage ses collaborateurs à agir avec intégrité, à défendre ce qui est juste et à viser l'excellence dans chaque mission. PwC valorise également l'impact positif, en incitant chacun à rester attentif aux évolutions de la société et à contribuer, par son travail, au progrès collectif. Le respect et l'attention portée aux autres occupent une place centrale, tout comme la collaboration, qui repose sur le partage des idées, la diversité des perspectives et l'amélioration continue par le feedback. Enfin, PwC cultive un esprit d'innovation en encourageant l'audace, l'expérimentation et l'ouverture à de nouvelles approches, afin de réinventer en permanence ce qu'il est possible d'accomplir.

1.3 PwC Tunisie

1.3.1 Présentation générale

PwC Tunisie est la représentation nationale du réseau PwC et opère depuis plusieurs décennies comme un acteur de référence dans les domaines de l'audit, du conseil et des services professionnels. Grâce à une équipe pluridisciplinaire composée de consultants, d'auditeurs et d'experts sectoriels, le cabinet accompagne les organisations tunisiennes et internationales dans leurs projets de transformation, de conformité et de performance. Sa proximité avec le tissu économique local, combinée à l'accès aux ressources et méthodologies du réseau mondial, lui permet d'offrir des solutions adaptées aux réalités du marché tunisien tout en respectant les standards internationaux.

1.3.2 Fiche signalétique de PwC Tunisie

- **Dénomination** : PwC Tunisie
- **Statut** : Cabinet membre du réseau PwC International
- **Localisation** : Tunis, Tunisie
- **Domaines d'intervention** : Audit financier, conseil, fiscalité, audit IT, gestion des risques, transformation digitale
- **Clientèle** : Entreprises privées, institutions publiques, banques, assurances, ONG, multinationales implantées en Tunisie
- **Rattachement** : PricewaterhouseCoopers International Limited (PwCIL)

Cette fiche reflète la structure agile et multidisciplinaire du cabinet, qui s'appuie sur l'expertise locale tout en bénéficiant du soutien du réseau mondial.

1.3.3 Offres de services de PwC Tunisie

PwC Tunisie propose une gamme complète de services destinés à accompagner les organisations dans leurs enjeux stratégiques, opérationnels et réglementaires. Les principales offres couvrent :

- **Audit et assurance** : certification des états financiers, audit légal, audit interne, contrôle interne.
- **Conseil** : stratégie, organisation, transformation digitale, amélioration de la performance.
- **Fiscalité et juridique** : optimisation fiscale, conformité réglementaire, assistance juridique.
- **Audit IT et cybersécurité** : évaluation des systèmes d'information, gestion des risques technologiques, sécurité informatique.
- **Data & Analytics** : exploitation des données, modélisation avancée, solutions IA.

Ces services permettent au cabinet d'accompagner ses clients dans des environnements complexes où les exigences réglementaires et technologiques évoluent rapidement.




FIGURE 1.4 – Organigramme simplifié de PwC Tunisie

1.3.4 Vue d'ensemble des lignes de services

Les activités de PwC Tunisie sont structurées autour de plusieurs lignes de services complémentaires, chacune spécialisée dans un domaine précis :

- **Assurance** : audit financier, revue de conformité, certification.
- **Advisory** : conseil en management, transformation digitale, stratégie opérationnelle.
- **Tax & Legal** : fiscalité, droit des affaires, conformité réglementaire.
- **Risk Assurance** : audit IT, gestion des risques, cybersécurité, data analytics.

Cette organisation permet de mobiliser des équipes multidisciplinaires et de proposer des solutions intégrées répondant aux besoins variés des clients.

1.3.5 Références clients

PwC Tunisie accompagne un large éventail d'organisations issues de secteurs variés : banques, assurances, télécommunications, industrie, énergie, distribution, services publics et ONG. Le cabinet intervient aussi bien auprès de grandes entreprises nationales que de filiales de groupes internationaux implantés en Tunisie. Cette diversité de clients témoigne de la confiance accordée au cabinet et de sa capacité à répondre à des problématiques complexes et spécifiques à chaque secteur.




FIGURE 1.5 – Secteurs clients de PwC Tunisie

1.4 Cadre du projet de fin d'études

1.4.1 Contexte du projet de fin d'études

Ce projet de fin d'études s'inscrit dans le cadre d'un stage réalisé au sein du département *Risk Assurance Services* de PwC Tunisie, une entité spécialisée dans l'audit IT, la gestion des risques et l'accompagnement des organisations dans leur transformation digitale. Dans un contexte où les entreprises traitent des volumes croissants de données financières, la détection manuelle des anomalies devient difficile, coûteuse et sujette à des erreurs humaines. Les équipes d'audit expriment ainsi un besoin croissant d'outils intelligents capables d'automatiser l'analyse, d'identifier rapidement les transactions suspectes et de fournir des explications claires pour appuyer la prise de décision. C'est dans cette dynamique que s'inscrit ce projet, dont l'objectif est de concevoir une solution technologique moderne, basée sur l'intelligence artificielle, permettant d'améliorer l'efficacité et la qualité des missions d'audit financier.

1.4.2 Problématique

Les auditeurs de PwC Tunisie sont régulièrement confrontés à des fichiers de transactions contenant plusieurs dizaines, voire centaines de milliers de lignes. Dans ces ensembles volumineux, les cas frauduleux représentent une proportion extrêmement

faible, souvent inférieure à 0,2 %. Leur identification manuelle est non seulement chronophage, mais également limitée par la capacité humaine à repérer des schémas subtils ou des signaux faibles noyés dans un bruit statistique important. La problématique centrale du projet peut ainsi être formulée comme suit :

Comment concevoir un système d'intelligence artificielle capable de détecter automatiquement les transactions financières anormales dans des jeux de données volumineux et fortement déséquilibrés, tout en fournissant aux auditeurs des explications compréhensibles justifiant chaque alerte ?

Cette problématique combine trois enjeux majeurs : la performance de détection, la gestion du déséquilibre des classes et l'interprétabilité des résultats.

1.4.3 Objectifs du projet

Pour répondre à la problématique identifiée, le projet poursuit plusieurs objectifs complémentaires, couvrant l'ensemble du cycle de traitement des données :

- **Détection automatique** : développer des modèles de machine learning capables d'identifier les transactions frauduleuses avec un niveau de rappel élevé.
- **Gestion du déséquilibre** : mettre en œuvre des techniques adaptées (pondération des classes, SMOTE) pour traiter l'extrême rareté des cas frauduleux.
- **Explicabilité** : intégrer des mécanismes d'explication (SHAP, LIME, LLM) permettant aux auditeurs de comprendre les raisons derrière chaque prédiction.
- **Adaptabilité** : concevoir un pipeline capable de s'adapter automatiquement à des schémas de données non standardisés grâce à un mapping sémantique robuste.
- **Déploiement** : proposer une plateforme web complète, incluant gestion des utilisateurs, missions d'audit, analyses et génération de rapports.

Ces objectifs visent à fournir une solution opérationnelle, fiable et directement exploitable par les équipes PwC.

1.4.4 Critères de succès

La réussite du projet repose sur plusieurs critères mesurables, définis en accord avec les besoins du département Risk Assurance Services :

- **Performance de détection** : atteindre un rappel élevé sur les transactions frauduleuses, tout en maintenant un taux raisonnable de faux positifs.
- **Robustesse du pipeline** : garantir une exécution stable et reproductible sur différents jeux de données, y compris ceux présentant des schémas non standard.
- **Qualité des explications** : fournir des interprétations claires, cohérentes et compréhensibles par des auditeurs non spécialistes en data science.

- **Intégration technique** : assurer le déploiement d’une plateforme web fonctionnelle, sécurisée et conforme aux standards internes de PwC.
- **Valeur ajoutée métier** : permettre un gain réel de temps et de précision dans les missions d’audit financier.

Ces critères constituent la base d’évaluation du projet et garantissent son alignement avec les attentes opérationnelles du cabinet.

1.5 Méthodologie CRISP-DM

1.5.1 Présentation et justification du choix

Pour structurer ce projet, la méthodologie **CRISP-DM** (Cross-Industry Standard Process for Data Mining) a été retenue comme cadre de référence. Développée à la fin des années 1990, elle est aujourd’hui l’une des approches les plus utilisées dans les projets de data science, aussi bien en milieu académique qu’en entreprise. Sa force réside dans sa capacité à organiser un projet autour de six phases complémentaires : compréhension métier, compréhension des données, préparation, modélisation, évaluation et déploiement. CRISP-DM a été choisie pour plusieurs raisons. D’abord, elle met l’accent sur la **dimension métier**, indispensable dans un contexte d’audit financier où les objectifs doivent être clairement définis avant toute manipulation des données. Ensuite, son caractère **itératif** permet de revenir facilement sur les étapes précédentes, ce qui est essentiel dans un projet de détection d’anomalies nécessitant de nombreux ajustements entre exploration, préparation et modélisation. Enfin, cette méthodologie est **agnostique vis-à-vis des outils**, ce qui la rend parfaitement compatible avec l’écosystème Python utilisé dans ce projet.




FIGURE 1.6 – Cycle CRISP-DM

1.5.2 Comparaison avec les autres méthodologies

Plusieurs méthodologies existent pour encadrer les projets de data science, mais toutes ne répondent pas aux exigences d'un projet d'audit IT. Par exemple, la méthode **SEMMA**, proposée par SAS, se concentre principalement sur la modélisation statistique et ne prend pas en compte la phase métier ni le déploiement, deux éléments pourtant essentiels dans ce projet. De son côté, la méthodologie **KDD** offre un cadre théorique solide, mais reste davantage orientée recherche que mise en production.

Les approches plus récentes, comme **Agile Data Science** ou **TDSP** (Team Data Science Process), sont adaptées aux environnements DevOps et aux équipes multidisciplinaires, mais elles supposent une infrastructure CI/CD avancée qui dépasse le cadre d'un projet individuel de fin d'études.

Dans ce contexte, CRISP-DM apparaît comme la méthodologie la plus pertinente : elle couvre l'ensemble du cycle de vie du projet, s'adapte aux contraintes d'un environnement d'audit et permet une structuration claire du travail réalisé.

1.5.3 Application au projet

L'ensemble du travail mené dans ce projet suit fidèlement les six phases de CRISP-DM. La phase de *Business Understanding* a permis de définir la problématique, les objectifs et les critères de succès en lien avec les besoins des auditeurs de PwC Tunisie. La phase de *Data Understanding* a consisté à analyser le jeu de données, à étudier ses distributions et à identifier les risques de leakage.

La phase de *Data Preparation* a regroupé les opérations de nettoyage, d'ingénierie de variables, de normalisation et de gestion du déséquilibre. La phase de *Modeling* a permis de comparer plusieurs approches supervisées et non supervisées, tandis que la phase d'*Evaluation* a servi à sélectionner le modèle le plus adapté selon des métriques pertinentes pour un contexte de fraude. Enfin, la phase de *Deployment* s'est concrétisée par la mise en place d'une plateforme web complète intégrant les modèles, les explications et la génération de rapports.

Cette structuration méthodologique a permis de garantir la cohérence, la rigueur et la reproductibilité du travail réalisé.

1.6 Conclusion du chapitre

Ce premier chapitre a permis de situer le projet dans son environnement institutionnel et professionnel. La présentation du réseau PwC, puis de PwC Tunisie, a mis en évidence le rôle stratégique du département Risk Assurance Services dans l'accompagnement des organisations face aux enjeux technologiques et financiers actuels. Le cadre du projet a clarifié la problématique à résoudre, les objectifs à atteindre et les

critères de succès attendus par les équipes d'audit.

Enfin, la méthodologie CRISP-DM a été introduite comme fil conducteur structurant l'ensemble du travail. Les chapitres suivants détailleront chacune de ses phases, depuis la compréhension métier jusqu'au déploiement de la solution, en passant par l'analyse des données, la préparation, la modélisation et l'évaluation.

2. Analyse et spécification des besoins

2.1 Introduction

Ce chapitre constitue la première étape de la méthodologie CRISP-DM appliquée à ce projet : la compréhension métier. Avant toute manipulation des données ou construction de modèles, il est essentiel de cerner le contexte dans lequel s'inscrit la détection d'anomalies financières, d'identifier les enjeux auxquels sont confrontés les auditeurs et de comprendre les limites des approches traditionnelles. Cette analyse permet de traduire les besoins métier en exigences techniques et de définir les fondations sur lesquelles reposera l'ensemble du pipeline de détection.

2.2 Contexte métier : la fraude dans l'audit financier

2.2.1 Définition et typologies de la fraude

La fraude financière désigne tout acte intentionnel visant à obtenir un avantage indu au détriment d'une organisation ou d'un tiers. Dans le domaine de l'audit, elle peut prendre différentes formes, allant du détournement d'actifs à la manipulation d'informations comptables. Les typologies les plus courantes incluent :

- **Le détournement d'actifs** : il s'agit de la forme de fraude la plus répandue, impliquant par exemple des virements non autorisés, des retraits injustifiés ou l'utilisation abusive des ressources de l'entreprise.
- **La fraude aux états financiers** : elle consiste à altérer volontairement les documents comptables afin de présenter une situation financière plus favorable qu'elle ne l'est réellement.
- **La corruption et les pratiques illicites** : elles regroupent les pots-de-vin, les conflits d'intérêts et les arrangements frauduleux entre parties internes et externes.

Dans le contexte spécifique des transactions électroniques, certaines formes de fraude se manifestent par des transferts non autorisés, des mouvements de fonds inhabituels ou des variations anormales de solde suivies d'un retrait rapide. Ces comportements, souvent subtils, nécessitent des outils d'analyse avancés pour être détectés efficacement.

2.2.2 Enjeux économiques et réglementaires

La fraude financière représente un enjeu majeur pour les institutions, tant sur le plan économique que réglementaire. Les pertes liées aux activités frauduleuses se chiffrent chaque année en milliards de dollars à l'échelle mondiale, impactant directement la rentabilité des entreprises et la confiance des clients. Au-delà des pertes financières, les organisations doivent également faire face à des exigences réglementaires de plus en plus strictes en matière de contrôle interne, de transparence et de gestion des risques. Les normes internationales d'audit, telles que l'ISA 240, imposent aux auditeurs d'identifier et d'évaluer les risques de fraude dans les états financiers. De même, les réglementations sectorielles exigent la mise en place de mécanismes de surveillance continue des transactions. Dans ce contexte, disposer d'outils capables de détecter rapidement les anomalies devient indispensable pour répondre aux obligations légales et protéger les organisations contre les risques opérationnels.

2.2.3 Limites des systèmes à base de règles

Les systèmes traditionnels de détection reposent souvent sur des règles métier définies manuellement, telles que des seuils de montants, des listes de comptes sensibles ou des patterns connus. Bien qu'ils soient simples à interpréter, ces systèmes présentent plusieurs limites. D'abord, ils sont **rigides** : une fois définies, les règles ne s'adaptent pas spontanément aux nouvelles formes de fraude, qui évoluent rapidement. Ensuite, leur **maintenance est coûteuse**, car chaque modification nécessite une intervention humaine et une révision régulière. Enfin, ces approches génèrent souvent un **taux élevé de faux positifs**, ce qui surcharge les équipes d'audit et peut entraîner la détection de nombreuses transactions légitimes comme suspectes. L'apprentissage automatique permet de dépasser ces limites en apprenant directement à partir des données historiques, en identifiant des schémas complexes et en s'adaptant aux comportements émergents.

2.3 Identification des acteurs du système

2.3.1 Introduction

L'identification des acteurs constitue une étape essentielle pour comprendre comment les différents utilisateurs interagissent avec la plateforme de détection d'anomalies financières. Chaque acteur joue un rôle spécifique dans le processus d'audit, depuis l'importation des données jusqu'à l'analyse des résultats et la génération des rapports. Cette section présente les principaux intervenants ainsi que leurs responsabilités au sein du système.

2.3.2 Acteurs principaux et responsabilités

Le système développé dans le cadre de ce projet est destiné à être utilisé par plusieurs profils d'utilisateurs, chacun ayant des besoins et des responsabilités distincts :

- **Auditeur financier** : acteur principal du système, il importe les fichiers de transactions, lance les analyses, consulte les résultats et interprète les alertes générées par les modèles. Il s'appuie sur les explications fournies pour documenter ses conclusions dans le cadre de la mission d'audit.
- **Manager ou Senior Auditor** : il supervise les travaux réalisés par les auditeurs, valide les analyses, examine les transactions signalées comme suspectes et assure la cohérence des conclusions. Il peut également demander des réanalyses ou des ajustements.
- **Administrateur du système** : responsable de la gestion technique de la plateforme, il configure les accès, gère les utilisateurs, supervise les modèles déployés et veille au bon fonctionnement de l'infrastructure.
- **Client ou entité auditée (acteur indirect)** : bien qu'il n'interagisse pas directement avec la plateforme, il fournit les données transactionnelles et reçoit les conclusions de l'audit. Son rôle est essentiel dans la chaîne de valeur.

Ces acteurs interagissent de manière complémentaire pour garantir la qualité, la fiabilité et la traçabilité du processus d'audit.

2.3.3 Rôles et matrice d'accès (RBAC)

La plateforme repose sur un modèle de contrôle d'accès basé sur les rôles (RBAC), permettant d'attribuer à chaque utilisateur des permissions adaptées à ses responsabilités. Ce mécanisme garantit la sécurité du système, la confidentialité des données et la conformité aux exigences internes de PwC.

- **Auditeur** : accès aux fonctionnalités d'importation des données, lancement des analyses, consultation des résultats, téléchargement des rapports. Il ne peut pas modifier les paramètres globaux du système.
- **Manager** : accès aux résultats détaillés, validation des analyses, consultation des journaux d'audit, supervision des missions. Il dispose d'une vision plus large que l'auditeur.
- **Administrateur** : accès complet à la plateforme, gestion des utilisateurs, configuration des modèles, maintenance technique et supervision de la sécurité.

Ce modèle RBAC permet de structurer les interactions avec le système, d'éviter les erreurs de manipulation et de garantir que chaque utilisateur n'accède qu'aux informations nécessaires à l'exercice de ses fonctions.

2.4 Cas d'utilisation

2.4.1 Diagramme général des cas d'utilisation

Le diagramme général des cas d'utilisation illustre les interactions entre les différents acteurs du système (auditeur, manager, administrateur) et les fonctionnalités principales de la plateforme. Il met en évidence les actions clés telles que l'importation des données, l'exécution du pipeline de détection, la consultation des résultats et la génération des rapports.




FIGURE 2.1 – Vue Générale de diagramme de Cas d'Utilisation

2.4.2 Description détaillée des cas principaux

Les cas d'utilisation essentiels du système sont décrits ci-dessous. Ils correspondent aux actions réalisées le plus fréquemment par les utilisateurs dans le cadre d'une mission d'audit.

- **Importer un fichier de transactions** : l'auditeur sélectionne un fichier fourni par le client et l'importe dans la plateforme. Le système vérifie la structure, applique le mapping sémantique et prépare les données pour l'analyse.




FIGURE 2.2 – Importation et préparation des données

- **Lancer l'analyse de détection** : une fois les données validées, l'auditeur déclenche le pipeline de détection. Les modèles supervisés et non supervisés sont

exécutés afin d'identifier les transactions suspectes.




FIGURE 2.3 – Lancement de l'analyse de détection

- **Consulter les résultats et les explications** : l'auditeur accède aux scores de risque, aux alertes générées et aux explications associées. Ces informations facilitent l'interprétation des anomalies détectées.




FIGURE 2.4 – Consultation des résultats et explications

- **Valider les alertes** : le manager examine les transactions signalées et valide ou rejette les conclusions de l'auditeur. Cette étape garantit la cohérence et la qualité du travail d'audit.




FIGURE 2.5 – Validation des alertes

- **Générer un rapport** : la plateforme permet de produire un rapport d'audit contenant les résultats, les visualisations et les explications nécessaires à la documentation de la mission.




FIGURE 2.6 – Génération de rapport d’audit

2.4.3 Diagrammes de séquence

Les diagrammes de séquence décrivent le déroulement temporel des interactions entre les acteurs et le système pour les cas d’utilisation les plus critiques. Ils permettent de visualiser la dynamique des échanges et de préciser le comportement attendu du système. Les séquences les plus pertinentes concernent :

- l’importation et la validation des données :




FIGURE 2.7 – Importation et validation des données

- l'exécution du pipeline de détection :
- la consultation des résultats et des explications :
- la génération du rapport final :

2.5 Modèle de données du domaine

2.5.1 Diagramme général des classes

Le diagramme général des classes!!




FIGURE 2.8 – Diagramme de classes général

2.5.2 Diagrammes de classes détaillés

2.5.2.1 Data Layer & Core Domain

Ce diagramme représente la couche centrale du domaine métier. Il regroupe les entités fondamentales manipulées par la plateforme : utilisateurs, missions, jeux de données, exécutions d'analyse et journaux d'audit. Ces classes structurent l'ensemble du workflow d'audit, depuis la création d'une mission jusqu'à la traçabilité des actions réalisées par les utilisateurs.

Les relations entre les entités reflètent le fonctionnement réel d'une mission d'audit : un utilisateur peut être associé à plusieurs missions, chaque mission peut contenir plusieurs jeux de données, et chaque jeu de données peut donner lieu à plusieurs exécutions d'analyse. Le journal d'audit permet de conserver une trace des actions effectuées, garantissant ainsi la conformité et la transparence du processus.




FIGURE 2.9 – Diagramme de classes général

2.5.2.2 ML Pipeline, Models & Backend Services

Ce diagramme détaille la structure interne du pipeline de détection d'anomalies. Il met en évidence les composants responsables de la préparation des données, de la construction des features, de l'exécution des modèles et de la génération des explications.

La couche « Pipeline ML » regroupe les objets produits lors de l'analyse : profils de colonnes, résultats de mapping, rapports d'ingénierie et réponses de prédiction. La couche « Modèles ML » présente les différents algorithmes utilisés, qu'ils soient supervisés ou non supervisés. Enfin, la couche « Services Backend » illustre les modules applicatifs qui orchestrent l'ensemble du processus : profilage, détection de schéma, construction dynamique des features, prédiction, explicabilité et génération de rapports.

Ce diagramme montre comment les différents services collaborent pour produire une analyse complète, reproductible et explicable.




FIGURE 2.10 – Diagramme de classes : ML Pipeline + Models + Services

2.5.2.3 API & Frontend Layer

Ce diagramme illustre la couche d'interaction entre les utilisateurs et le système. La partie API, développée avec FastAPI, expose les points d'entrée permettant de lancer des prédictions, d'obtenir des explications, de générer des rapports ou de consulter les modèles disponibles. Chaque route correspond à une fonctionnalité métier clairement définie.

La partie Frontend, construite avec Next.js, regroupe les services et contextes utilisés par l'interface utilisateur : authentification, gestion des missions, exécution des analyses et génération des rapports. Ces composants communiquent directement avec les routes API, assurant une interaction fluide et cohérente entre l'utilisateur et le backend.

Ce diagramme met en évidence la séparation claire entre les responsabilités : l'API gère la logique métier et les traitements, tandis que le frontend se concentre sur l'expérience utilisateur.




FIGURE 2.11 – Diagramme de classes : API + Frontend Layer

2.5.3 Entités principales

Les entités principales du domaine représentent les objets manipulés par le système tout au long du processus d'audit. Elles sont au cœur du modèle conceptuel et structurent les interactions entre les différentes couches fonctionnelles.

Utilisateur Représente toute personne ayant accès à la plateforme (auditeur, manager, administrateur). L'entité inclut les informations d'authentification, le rôle attribué et les permissions associées.

Mission d'audit Correspond à une mission confiée à PwC. Elle regroupe les fichiers de transactions, les analyses effectuées, les résultats obtenus et les rapports générés.

Jeu de données Désigne un fichier de transactions importé dans le système. Il contient les opérations financières, leurs attributs et les métadonnées associées (source, date d'importation, schéma détecté).

Transaction Représente une opération financière individuelle. C'est l'entité centrale du pipeline de détection, analysée par les modèles pour identifier les anomalies.

Résultat d'analyse Contient les scores de risque, les alertes générées et les explications associées. Cette entité permet aux auditeurs de comprendre et de documenter les anomalies détectées.

Rapport Regroupe les conclusions finales de l'audit, les visualisations et les éléments justificatifs. Il constitue le livrable transmis au client.

Ces entités interagissent de manière cohérente pour permettre l'exécution complète du processus d'audit, depuis l'importation des données jusqu'à la génération du rapport final.

2.6 Backlog produit et planification agile

2.6.1 Introduction

Le développement de la plateforme a été organisé selon une approche agile, permettant d'itérer rapidement sur les fonctionnalités prioritaires et d'ajuster le périmètre en fonction des besoins métier. Le backlog produit regroupe l'ensemble des fonctionnalités attendues, structurées sous forme de user stories. Les éléments présentés ci-dessous correspondent aux priorités identifiées pour les premières itérations du projet.

2.6.2 User stories prioritaires

Les user stories suivantes représentent les besoins essentiels exprimés par les auditeurs, les managers et les administrateurs. Elles ont été classées selon leur priorité et leur complexité estimée.

- **US-01 - Importation et analyse des transactions** En tant qu'auditeur, je peux importer un fichier CSV et obtenir une liste de transactions suspectes

classées par niveau de risque.

- **US-02 - Explication d’une transaction** En tant qu’auditeur, je peux consulter une explication détaillée (SHAP) pour comprendre pourquoi une transaction a été signalée.
- **US-03 - Génération de rapport** En tant qu’auditeur, je peux générer un rapport PDF conforme aux standards PwC.
- **US-04 - Gestion des missions** En tant que manager, je peux créer des missions et y rattacher des jeux de données.
- **US-05 - Consultation de la piste d’audit** En tant qu’administrateur, je peux consulter l’historique complet des actions réalisées sur la plateforme.
- **US-06 - Détection automatique du schéma** En tant qu’auditeur, le système détecte automatiquement la structure de mon fichier et propose un mapping sémantique.
- **US-07 - Explication en langage naturel** En tant qu’auditeur, je peux obtenir une explication générée par un LLM pour faciliter la compréhension métier.
- **US-08 - Gestion du registre des modèles** En tant qu’administrateur, je peux consulter les versions des modèles et promouvoir un modèle en production.

2.6.3 Planification en sprints

La planification a été organisée en quatre sprints successifs, chacun d’une durée de deux semaines. Cette organisation permet de livrer progressivement les fonctionnalités clés tout en assurant une montée en puissance cohérente du système.

Sprint 1 - Analyse et prédiction Implémentation de l’importation CSV, du pipeline de prédiction, de la détection de schéma et des premières explications SHAP.

Sprint 2 - Reporting et gestion des missions Ajout de la génération de rapports PDF, de la gestion des missions et de l’interface associée.

Sprint 3 - Explicabilité avancée et audit Intégration du module LLM pour les explications en langage naturel et mise en place de la piste d’audit.

Sprint 4 - Administration et stabilisation Gestion du registre des modèles, optimisation du backend et stabilisation de l’ensemble de la plateforme.

Cette planification progressive garantit une livraison continue de valeur tout en permettant d’ajuster les priorités selon les retours métier.

2.7 Architecture fonctionnelle

L’architecture fonctionnelle de la plateforme repose sur une organisation en couches, permettant de séparer clairement les responsabilités et de garantir la maintenabilité du système. Elle s’articule autour de quatre niveaux complémentaires :

- **Couche Présentation (Frontend)** : développée avec Next.js, elle offre une interface moderne permettant aux auditeurs et managers d’interagir avec la plateforme, de gérer les missions et de visualiser les résultats.
- **Couche API (Backend FastAPI)** : expose les services REST nécessaires à l’analyse, à l’explication, à la gestion des missions et à la génération des rapports. L’authentification repose sur des tokens JWT.
- **Couche Machine Learning** : regroupe les modèles de détection (XGBoost, AutoEncoder, Isolation Forest) ainsi que les modules d’explicabilité (SHAP, LIME, LLM).
- **Couche Données** : s’appuie sur PostgreSQL pour la persistance des entités métier et sur un système de fichiers sécurisé pour le stockage des fichiers CSV importés.

Cette architecture modulaire permet d’assurer une séparation nette entre les préoccupations métier, les traitements analytiques et l’interface utilisateur, tout en facilitant l’évolution future du système.

2.8 Conclusion du chapitre

Ce chapitre a permis de formaliser les besoins fonctionnels et techniques de la plateforme à travers l’identification des acteurs, la définition des cas d’utilisation, la modélisation du domaine et la planification agile du développement. L’architecture fonctionnelle présentée constitue la base sur laquelle repose l’ensemble du système. Ces éléments servent de référence pour les phases suivantes, qui détailleront la mise en œuvre du pipeline de données, la préparation des variables, la modélisation et l’évaluation des performances.

3. Compréhension et préparation des données

3.1 Introduction

La compréhension des données constitue une étape fondamentale dans tout projet de data science. Avant d'appliquer des techniques de préparation ou de modélisation, il est indispensable d'examiner la structure du jeu de données, d'en évaluer la qualité et d'identifier les caractéristiques susceptibles d'influencer la détection des anomalies. Cette phase permet également de repérer les incohérences, les valeurs manquantes, les biais potentiels et les risques de fuite d'information.

Dans ce projet, l'analyse exploratoire a joué un rôle central pour orienter les choix méthodologiques, définir les variables pertinentes et anticiper les difficultés liées au déséquilibre extrême des classes. Les sections suivantes présentent l'origine du jeu de données, la description des variables brutes et le bilan de qualité réalisé avant la préparation.

3.2 Présentation du jeu de données

3.2.1 Origine et description du simulateur

Le jeu de données utilisé dans ce projet provient d'un simulateur de transactions financières largement utilisé dans les travaux de recherche et les projets d'audit analytique. Ce simulateur reproduit le comportement d'un système de paiement électronique à grande échelle, en générant des opérations variées (transferts, retraits, paiements, dépôts) ainsi que des scénarios de fraude réalistes.

Les données sont entièrement anonymisées et ne contiennent aucune information permettant d'identifier des individus ou des organisations réelles. Elles ont été sélectionnées pour leur richesse, leur volume et leur pertinence dans le cadre d'un projet de détection d'anomalies financières. Le corpus comprend plusieurs centaines de milliers de transactions, réparties sur plusieurs jours simulés, avec un taux de fraude extrêmement faible, reflétant les conditions réelles observées dans les environnements bancaires.

3.2.2 Description des variables brutes

Le tableau suivant présente les principales variables du jeu de données brut. Elles décrivent les caractéristiques essentielles de chaque transaction : type d’opération, montants, identifiants des comptes et soldes avant et après l’opération.

Variable	Type	Description
step	Entier	Pas de temps représentant l’heure de la transaction dans la simulation.
type	Catégorie	Type d’opération : CASH_IN, CASH_OUT, DEBIT, PAYMENT, TRANSFER.
amount	Réel	Montant de la transaction.
nameOrig	Chaîne	Identifiant anonymisé du compte émetteur.
oldbalanceOrg	Réel	Solde du compte émetteur avant la transaction.
newbalanceOrig	Réel	Solde du compte émetteur après la transaction.
nameDest	Chaîne	Identifiant anonymisé du compte destinataire.
oldbalanceDest	Réel	Solde du compte destinataire avant la transaction.
newbalanceDest	Réel	Solde du compte destinataire après la transaction.
isFraud	Binaire	Indicateur de fraude (1 = transaction frauduleuse).
isFlaggedFraud	Binaire	Indicateur d’un système de règles interne.

TABLE 3.1 – Description des variables brutes du jeu de données

3.2.3 Qualité et bilan des données

L’analyse de la qualité des données a permis d’identifier plusieurs éléments importants pour la suite du projet :

- **Déséquilibre extrême des classes** : les transactions frauduleuses représentent une proportion infime du corpus. Ce déséquilibre impose l’utilisation de métriques adaptées (Recall, PR-AUC) et de techniques de rééchantillonnage.
- **Incohérences dans les soldes** : certaines variables de solde présentent des valeurs incohérentes, notamment pour les transactions frauduleuses. Ces anomalies peuvent introduire une fuite d’information si elles sont utilisées directement dans les modèles.
- **Distribution fortement asymétrique des montants** : la variable *amount* présente une asymétrie marquée, justifiant l’application d’une transformation logarithmique lors de la préparation.

- **Absence de valeurs manquantes** : le jeu de données ne contient pas de valeurs manquantes, ce qui facilite la préparation mais n'exclut pas la nécessité de vérifier la cohérence des valeurs.
- **Variabilité des types de transactions** : seuls certains types d'opérations (TRANSFER, CASH_OUT) présentent des cas de fraude, ce qui constitue une information clé pour l'ingénierie de variables.

Ce bilan a permis de définir les transformations nécessaires pour préparer les données et éviter les biais lors de la modélisation.

3.3 Analyse exploratoire des données (EDA)

L'analyse exploratoire des données constitue une étape essentielle pour comprendre la structure du jeu de données, identifier les tendances générales et repérer les signaux caractéristiques associés aux transactions frauduleuses. Cette phase permet également de détecter les incohérences, les biais potentiels et les variables susceptibles d'introduire une fuite d'information. Les observations présentées ci-dessous ont guidé la préparation des données et la construction des variables dérivées.

3.3.1 Déséquilibre des classes

Le premier constat majeur concerne la répartition extrêmement déséquilibrée entre les transactions légitimes et frauduleuses. Les fraudes représentent une proportion infime du corpus, avec un ratio proche de 1 pour 774. Un modèle naïf prédisant systématiquement la classe « normale » atteindrait une exactitude très élevée, mais serait incapable de détecter la moindre fraude.

Ce déséquilibre impose l'utilisation de métriques adaptées (Recall, PR-AUC, F1-score) ainsi que de techniques de rééchantillonnage ou de pondération lors de la modélisation. Il justifie également la nécessité d'un pipeline robuste capable de traiter des signaux rares et souvent subtils.

3.3.2 Distribution des montants et types de transactions

L'analyse de la variable *amount* révèle une distribution fortement asymétrique : la majorité des transactions portent sur de faibles montants, tandis qu'une minorité présente des valeurs très élevées. Cette asymétrie justifie l'application d'une transformation logarithmique pour stabiliser la variance et améliorer la performance des modèles sensibles aux échelles.

La répartition des types d'opérations montre une prédominance des transactions PAYMENT et CASH_OUT. Toutefois, l'analyse du taux de fraude par type révèle un point clé : les fraudes ne se produisent que dans les opérations TRANSFER et

CASH_OUT. Les autres types (CASH_IN, DEBIT, PAYMENT) sont systématiquement légitimes dans ce jeu de données.

Cette observation a conduit à la création d’une variable dérivée indiquant si la transaction appartient à l’un des types susceptibles de contenir des fraudes.

3.3.3 Analyse temporelle et comportementale

L’étude de la variable temporelle *step*, représentant l’heure simulée de la transaction, met en évidence une concentration des fraudes durant les heures creuses. Les périodes situées entre minuit et 9h, ainsi que l’heure 23, présentent un taux de fraude nettement supérieur à la moyenne.

Ce comportement suggère que les fraudeurs privilégient les moments où la surveillance est réduite. Cette observation a motivé la création d’une variable indicatrice *high_risk_hour*, qui s’est révélée particulièrement discriminante lors de la modélisation.

3.3.4 Analyse des soldes et détection de leakage

L’analyse des variables de solde (*oldbalanceOrg*, *newbalanceOrig*, *oldbalanceDest*, *newbalanceDest*) met en évidence des incohérences caractéristiques des transactions frauduleuses. Par exemple, dans une grande majorité des fraudes TRANSFER, le solde de l’émetteur devient nul après l’opération, ce qui correspond à un vidage complet du compte. De même, de nombreuses fraudes CASH_OUT sont dirigées vers des comptes dont le solde initial est nul, suggérant l’utilisation de comptes mules.

Ces variables, bien que très informatives, peuvent introduire une fuite d’information si elles sont utilisées directement dans les modèles. Pour éviter ce biais, des variables dérivées plus générales ont été créées, telles que *balance_diff_orig*, qui capture la variation du solde sans révéler explicitement la fraude.

3.3.5 Baseline de la règle métier existante

Le jeu de données inclut un indicateur binaire *isFlaggedFraud*, correspondant à un système de règles métier simple utilisé comme baseline. L’évaluation de cette règle montre des performances très faibles : elle ne détecte qu’une fraction infime des fraudes réelles, avec un rappel quasi nul.

Cette baseline illustre les limites des approches heuristiques dans un contexte où les fraudeurs adaptent continuellement leurs méthodes. Elle justifie pleinement le recours à des techniques d’apprentissage automatique capables de capturer des schémas plus complexes et moins prévisibles.

3.4 Pipeline de préparation des données

La préparation des données constitue l’une des étapes les plus importantes du projet. Elle vise à transformer les données brutes en un format exploitable par les modèles tout en garantissant l’absence de fuite d’information et la cohérence statistique des transformations. Le pipeline mis en place suit une démarche progressive : suppression des variables sensibles, création de nouvelles variables, division stratifiée du corpus et normalisation contrôlée.

3.4.1 Suppression des variables à risque de leakage

Certaines variables du jeu de données initial présentent un risque élevé de fuite d’information. Leur présence dans les modèles pourrait conduire à des performances artificiellement élevées, impossibles à reproduire en production. Ces variables ont donc été retirées dès le début du pipeline.

Les principales raisons de suppression sont les suivantes :

- **Identifiants directs (nameOrig, nameDest)** : ces identifiants anonymisés ne sont pas exploitables tels quels et peuvent conduire à un surapprentissage.
- **Variables de solde (oldbalanceOrg, newbalanceOrig, oldbalanceDest, newbalanceDest)** : ces valeurs permettent parfois de déduire directement la fraude, ce qui constitue une fuite structurelle.
- **isFlaggedFraud** : indicateur issu d’un système de règles existant, trop corrélé à la cible.

La suppression de ces variables garantit que les modèles apprennent des signaux réellement exploitables en situation réelle.

3.4.2 Ingénierie de variables

L’ingénierie de variables a permis d’enrichir le jeu de données avec des informations plus pertinentes que les variables brutes. Trois familles de variables dérivées ont été construites : temporelles, comportementales et liées aux soldes.

Variables temporelles À partir de la variable *step*, plusieurs indicateurs ont été dérivés :

- **hour** : heure de la journée (0–23) ;
- **day** : jour de la simulation ;
- **week** : semaine simulée ;
- **high_risk_hour** : indicateur des heures à risque élevé.

Variables liées aux soldes Ces variables capturent la dynamique des comptes émetteurs et destinataires :

- **balance_diff_orig** : variation du solde émetteur ;

- **dest_zero_balance** : indicateur de solde nul du destinataire ;
- **eng_amount_ratio_src** : ratio entre le montant et le solde disponible.

Variables comportementales Elles décrivent l'activité historique des comptes :

- **eng_orig_tx_count** : nombre de transactions de l'émetteur ;
- **eng_orig_unique_dests** : diversité des destinataires ;
- **eng_dest_tx_count** : nombre de transactions reçues par le destinataire.

Ces variables dérivées se sont révélées particulièrement discriminantes pour la détection des comportements frauduleux.

3.4.3 Ensemble final de variables

Après suppression des variables sensibles et création des variables dérivées, l'ensemble final utilisé pour l'entraînement des modèles comprend quatorze variables. Elles couvrent les dimensions temporelles, comportementales, monétaires et catégorielles.

- **Temporelles** : step, hour, day, week ;
- **Montant** : log_amount ;
- **Comportement** : balance_diff_orig ;
- **Binaires** : high_risk_hour, is_transfer_or_cashout, dest_zero_balance ;
- **Types encodés** : type_CASH_IN, type_CASH_OUT, type_DEBIT, type_PAYMENT, type_TRANSFER.

Cet ensemble constitue une base compacte mais riche, adaptée aux modèles supervisés et non supervisés utilisés dans le projet.

3.4.4 Division stratifiée

Le jeu de données a été divisé en trois sous-ensembles : entraînement, validation et test. La division a été réalisée de manière stratifiée afin de conserver le taux de fraude dans chaque partition, condition indispensable pour une évaluation fiable.

- **Entraînement** : 70
- **Validation** : 15
- **Test** : 15

Cette séparation garantit l'étanchéité entre les phases d'apprentissage, de réglage des hyperparamètres et d'évaluation finale.

3.4.5 Normalisation

La normalisation constitue une étape essentielle pour garantir la stabilité des modèles, en particulier ceux sensibles à l'échelle des variables. Le *StandardScaler* a été utilisé pour centrer et réduire les variables continues.

Conformément aux bonnes pratiques, le scaler a été ajusté uniquement sur l'ensemble d'entraînement, puis appliqué aux ensembles de validation et de test. Cette

discipline stricte permet d'éviter toute fuite d'information statistique provenant des données de test.

3.5 Gestion du déséquilibre de classes

Le jeu de données présente un déséquilibre extrême entre les transactions légitimes et frauduleuses. Ce phénomène, courant dans les systèmes financiers réels, rend les modèles supervisés particulièrement sensibles au biais vers la classe majoritaire. Pour atténuer cet effet, plusieurs stratégies complémentaires ont été mises en place : la pondération des classes, la génération d'exemples synthétiques via SMOTE et la constitution d'un ensemble spécifique pour l'entraînement de l'autoencoder.

3.5.1 Pondération des classes

La première stratégie consiste à ajuster automatiquement le poids attribué à chaque classe lors de l'entraînement des modèles supervisés. La pondération permet de compenser la rareté des exemples frauduleux en leur attribuant un poids proportionnellement plus élevé.

La formule utilisée est celle de la pondération équilibrée :

$$w_c = \frac{N}{K \cdot n_c}$$

où :

- N est le nombre total d'exemples,
- K le nombre de classes,
- n_c le nombre d'exemples de la classe c .

Dans notre cas, la classe « fraude » reçoit un poids très élevé, reflétant sa rareté dans l'ensemble d'entraînement. Cette approche améliore la capacité des modèles à détecter les signaux faibles sans modifier la distribution réelle des données.

3.5.2 SMOTE

La seconde stratégie repose sur SMOTE (Synthetic Minority Over-sampling Technique), une méthode de sur-échantillonnage qui génère des exemples synthétiques de la classe minoritaire. Contrairement à une duplication simple, SMOTE crée de nouveaux points en interpolant entre des exemples existants de fraude.

Le principe est le suivant :

$$x_{syn} = x_i + \lambda \cdot (x_{knn} - x_i), \quad \lambda \sim U(0, 1)$$

où :

- x_i est un exemple réel de fraude,
- x_{knn} l'un de ses voisins les plus proches,
- λ un coefficient aléatoire.

Règle essentielle : SMOTE est appliqué uniquement sur l'ensemble d'entraînement, après le découpage stratifié. L'appliquer avant introduirait une fuite d'information, car des exemples synthétiques dérivés du train pourraient contaminer les ensembles de validation ou de test.

Après application de SMOTE, l'ensemble d'entraînement devient parfaitement équilibré, ce qui facilite l'apprentissage des modèles supervisés.

3.5.3 Ensemble dédié à l'autoencoder

L'autoencoder utilisé dans ce projet repose sur une approche non supervisée. Son objectif est d'apprendre la structure normale des transactions afin de détecter les anomalies par reconstruction.

Pour garantir un apprentissage fiable, un sous-ensemble spécifique a été constitué :

- il contient uniquement les transactions légitimes de l'ensemble d'entraînement ;
- aucune transaction frauduleuse n'est incluse ;
- aucune forme de sur-échantillonnage n'est appliquée.

Ce choix permet au modèle d'apprendre exclusivement la distribution normale. Les transactions frauduleuses, qui s'écartent fortement de cette distribution, produisent alors des erreurs de reconstruction plus élevées, facilitant leur détection.

3.6 Mapping sémantique automatique des colonnes

L'un des enjeux majeurs de la plateforme réside dans sa capacité à traiter des fichiers CSV provenant de sources variées, souvent hétérogènes et non standardisés. Les clients utilisent des conventions différentes pour nommer leurs colonnes : termes en français ou en anglais, abréviations internes, variations typographiques ou encore noms composites. Sans mécanisme d'adaptation, le pipeline échouerait dès l'étape d'importation. Pour répondre à cette problématique, un système de mapping sémantique automatique a été développé afin d'identifier et d'harmoniser les colonnes avant l'analyse.

3.6.1 Problématique des schémas non standards

Dans un contexte réel, il est rare que les fichiers transmis par les clients respectent un schéma uniforme. Une même colonne peut apparaître sous des formes très différentes :

- *amount, montant, amt, tx_amount* ;
- *type, transaction_type, nature_opération* ;
- *nameOrig, compte_source, sender_id*.

Cette diversité rend impossible l'utilisation d'un schéma figé. Le système doit être capable de reconnaître automatiquement les colonnes pertinentes, même lorsque leur nom diffère de celui attendu. Le module `ColumnMapper` répond à ce besoin en appliquant un ensemble de règles et de techniques de similarité pour associer chaque colonne à son équivalent interne.

3.7 Conclusion du chapitre

Ce chapitre a présenté l'ensemble des étapes nécessaires pour transformer les données brutes en un jeu exploitable par les modèles de détection d'anomalies. L'analyse exploratoire a permis d'identifier les caractéristiques clés du corpus, tandis que le pipeline de préparation a assuré la suppression des variables sensibles, la création de nouvelles variables pertinentes, la gestion du déséquilibre et la normalisation contrôlée des données.

Le système de mapping sémantique complète ce dispositif en permettant à la plateforme de traiter des fichiers aux schémas variés, garantissant ainsi une robustesse indispensable en contexte réel. L'ensemble de ces éléments constitue une base solide pour la phase suivante, consacrée à la modélisation et à l'évaluation des performances.

4. Modélisation et évaluation

4.1 Introduction

La phase de modélisation constitue le cœur technique du projet. Elle vise à transformer les données préparées en un système capable d'identifier automatiquement les transactions frauduleuses. Dans ce contexte, plusieurs familles d'algorithmes ont été explorées afin de couvrir à la fois les scénarios supervisés - où l'étiquette de fraude est connue - et les scénarios non supervisés, indispensables lorsque les données étiquetées sont rares ou absentes. Cette approche hybride permet d'obtenir un système robuste, capable de détecter des schémas connus tout en restant sensible à des comportements atypiques. Les sections suivantes présentent l'état de l'art des principales approches de détection, ainsi que les raisons ayant motivé le choix des modèles retenus pour la plateforme.

4.2 État de l'art des approches de détection

4.2.1 Approches supervisées

Les approches supervisées reposent sur l'existence d'un historique de transactions annotées comme frauduleuses ou légitimes. Elles apprennent à reproduire ce comportement en identifiant les motifs caractéristiques associés à la fraude.

Parmi les modèles les plus utilisés dans ce domaine, on retrouve :

- **Régression logistique** : modèle linéaire simple, efficace pour établir une première baseline.
- **Random Forest** : ensemble d'arbres de décision capable de capturer des interactions complexes entre variables.
- **XGBoost** : algorithme de boosting particulièrement performant sur les données tabulaires et adapté aux problèmes de déséquilibre.

Ces modèles offrent une bonne capacité de généralisation lorsque les données étiquetées sont suffisantes. Toutefois, leur performance dépend fortement de la qualité des labels et de la représentativité des fraudes historiques.

4.2.2 Approches non supervisées

Les approches non supervisées sont particulièrement utiles lorsque les données étiquetées sont rares, incomplètes ou inexistantes - une situation fréquente dans les environnements financiers. Elles reposent sur l'idée que les transactions frauduleuses diffèrent statistiquement des transactions normales.

Les méthodes les plus courantes incluent :

- **Autoencodeurs** : réseaux de neurones entraînés à reconstruire les transactions normales ; les anomalies produisent une erreur de reconstruction élevée.
- **Isolation Forest** : algorithme basé sur l'isolation aléatoire des points, particulièrement adapté aux anomalies rares et isolées.

Ces modèles permettent de détecter des comportements nouveaux ou inattendus, non présents dans l'historique des fraudes connues.

4.2.3 Justification des modèles retenus

La plateforme repose sur une combinaison de modèles supervisés et non supervisés afin de tirer parti des forces de chaque approche.

XGBoost a été retenu comme modèle supervisé principal en raison de :

- sa performance élevée sur les données tabulaires ;
- sa capacité à gérer le déséquilibre via *scale_pos_weight* ;
- sa robustesse face aux interactions non linéaires.

L'Autoencodeur a été choisi comme modèle non supervisé car il permet :

- d'apprendre la structure normale des transactions ;
- de détecter des anomalies inédites ;
- de fonctionner même en absence de labels fiables.

Isolation Forest complète l'architecture pour les cas où le schéma des colonnes est incomplet ou non standard, offrant une solution générique applicable à tout fichier.

Cette combinaison garantit une couverture optimale : détection des fraudes connues, identification des comportements atypiques et robustesse face aux variations de schéma.

4.3 Modèles supervisés

Les modèles supervisés constituent la première famille d'algorithmes explorée dans ce projet. Ils apprennent à distinguer les transactions légitimes des transactions frauduleuses à partir d'un historique annoté. Cette approche est particulièrement efficace lorsque les données étiquetées sont fiables et représentatives, ce qui est le cas du jeu de données utilisé pour l'entraînement. Trois modèles ont été retenus : la régression logistique, la forêt aléatoire et XGBoost. Ils offrent des niveaux de complexité croissants et permettent d'évaluer l'impact de différentes stratégies de gestion du déséquilibre.

4.3.1 Régression logistique

La régression logistique constitue le modèle linéaire de référence pour la classification binaire. Sa simplicité, sa rapidité d'entraînement et son interprétabilité en font un excellent point de départ pour établir une baseline.

Dans ce projet, deux variantes ont été évaluées :

- une version pondérée (*class_weight='balanced'*) pour compenser le ratio 1 :774 ;
- une version entraînée sur un ensemble rééchantillonné via SMOTE.

La version pondérée atteint un rappel très élevé mais génère un nombre important de faux positifs. À l'inverse, la version SMOTE offre un meilleur compromis entre rappel et précision, avec un F1 nettement supérieur. Ces résultats confirment que, malgré sa simplicité, la régression logistique constitue une baseline solide mais limitée pour capturer des interactions non linéaires.

4.3.2 Forêt aléatoire

La forêt aléatoire repose sur un ensemble d'arbres de décision entraînés sur des sous-échantillons aléatoires des données et des variables. Ce modèle est capable de capturer des interactions complexes entre les features, ce qui le rend particulièrement adapté aux données tabulaires enrichies par l'ingénierie de variables.

Deux variantes ont été testées :

- **RF_balanced** : entraîné sur les données brutes avec pondération automatique des classes ;
- **RF_smote** : entraîné sur les données rééquilibrées via SMOTE.

Les résultats montrent que la version SMOTE surpasse systématiquement la version pondérée, avec une précision plus élevée et un nombre de faux positifs réduit. La forêt aléatoire constitue ainsi une alternative robuste, capable d'exploiter efficacement les variables dérivées issues de l'EDA.

4.3.3 XGBoost

XGBoost est un algorithme de boosting par gradient particulièrement performant pour les données tabulaires. Il construit des arbres de décision de manière séquentielle, chaque arbre corrigeant les erreurs du précédent. Sa capacité à gérer le déséquilibre, à intégrer une régularisation explicite et à capturer des interactions complexes en fait un candidat idéal pour la détection de fraude.

Dans ce projet, XGBoost a été entraîné sur l'ensemble SMOTE afin de bénéficier d'un meilleur équilibre entre les classes. Les résultats obtenus sont les meilleurs parmi tous les modèles supervisés :

- PR-AUC supérieur à 0.90 sur validation ;
- précision et rappel équilibrés ;

- seulement quelques faux positifs sur l'ensemble de validation.
- XGBoost constitue ainsi le modèle supervisé de référence de la plateforme.

4.3.4 Optimisation des seuils de décision

Le seuil par défaut de 0.5 n'est pas adapté aux données fortement déséquilibrées. Pour chaque modèle, un seuil optimal a été déterminé sur l'ensemble de validation en maximisant la métrique F_β avec $\beta = 2$, qui accorde davantage d'importance au rappel.

Cette stratégie est justifiée par le contexte métier : dans un audit financier, manquer une fraude réelle est beaucoup plus coûteux que signaler une transaction légitime. L'optimisation du seuil permet donc d'ajuster finement le compromis entre rappel et précision.

Les seuils optimaux obtenus montrent des comportements différents selon les modèles :

- seuils très élevés pour la régression logistique (scores polarisés) ;
- seuils proches de 0.6 pour les forêts aléatoires ;
- seuil optimal autour de 0.35 pour XGBoost, reflétant une distribution de scores plus conservatrice.

L'application de ces seuils optimisés améliore significativement les performances finales, en particulier pour XGBoost, qui atteint un F1 supérieur à 0.83 sur le jeu de test.

4.4 Modèles non supervisés

Les approches non supervisées jouent un rôle essentiel dans la détection d'anomalies financières, en particulier lorsque les données étiquetées sont rares ou lorsque de nouveaux schémas de fraude apparaissent. Contrairement aux modèles supervisés, ces méthodes apprennent uniquement à partir des transactions normales et identifient les anomalies comme des observations qui s'écartent fortement de ce comportement. Deux modèles ont été étudiés : l'Autoencoder, basé sur un réseau de neurones, et l'Isolation Forest, fondé sur l'isolation aléatoire des points.

4.4.1 Autoencoder

L'Autoencoder est un réseau de neurones entraîné à reconstruire fidèlement les transactions normales. Il apprend une représentation comprimée (bottleneck) des données, puis tente de les reconstruire. Les transactions frauduleuses, qui ne suivent pas les mêmes patterns, produisent une erreur de reconstruction nettement plus élevée.

L'architecture retenue est symétrique : $14 \rightarrow 10 \rightarrow 7 \rightarrow [4] \rightarrow 7 \rightarrow 10 \rightarrow 14$. Elle comporte seulement 596 paramètres, ce qui limite le risque de surapprentissage et

favorise la généralisation.

L’entraînement est réalisé exclusivement sur les 139 818 transactions normales de l’ensemble d’apprentissage. Deux mécanismes de régulation sont utilisés : *EarlyStopping* pour éviter l’overfitting et *ReduceLROnPlateau* pour ajuster dynamiquement le taux d’apprentissage. Le modèle converge après 36 époques, avec une erreur de reconstruction stable et faible sur les données normales.

4.4.2 Détermination du seuil MSE optimal

La détection repose sur l’erreur de reconstruction (MSE). Plus cette erreur est élevée, plus la transaction est susceptible d’être frauduleuse. Un seuil doit donc être déterminé pour distinguer les anomalies des transactions normales.

Un premier seuil naïf est obtenu via le percentile 95 des erreurs sur les données normales. Toutefois, ce seuil est affiné en optimisant le F1-score sur l’ensemble de validation, en balayant un ensemble de seuils possibles.

Le seuil optimal obtenu est **1.75** (MSE brute), nettement supérieur au seuil initial. Ce seuil permet d’équilibrer rappel et précision dans un contexte non supervisé. Sur l’ensemble de test, l’Autoencoder atteint un rappel de 0.359 et une précision de 0.609, avec seulement 9 faux positifs sur 30 001 transactions.

4.4.3 Isolation Forest

L’Isolation Forest est un algorithme non supervisé basé sur l’isolation aléatoire des points dans un ensemble d’arbres binaires. Les anomalies, plus rares et plus distinctes, sont isolées en moins de coupures que les observations normales.

Le modèle est entraîné sur l’ensemble d’entraînement complet, sans utiliser les labels. Le paramètre *contamination* est fixé au taux de fraude observé (0.129).

Bien que rapide et simple à mettre en œuvre, l’Isolation Forest obtient des performances inférieures à celles de l’Autoencoder : rappel de 0.333 et F1 de 0.347 sur le test. Ce résultat s’explique par la présence de variables métier très discriminantes, que les modèles supervisés exploitent mieux que les approches non supervisées.

4.4.4 Visualisation de l’espace latent

L’espace latent de l’Autoencoder (dimension 4) offre une représentation compacte des transactions normales. Pour analyser la séparabilité entre transactions normales et frauduleuses, une projection en deux dimensions est réalisée via une analyse en composantes principales (PCA).

La visualisation montre que les transactions frauduleuses se situent majoritairement en périphérie du nuage de points normaux, confirmant que leur structure diffère significativement de celle des transactions légitimes. Cette représentation visuelle renforce

l'interprétation du modèle : les fraudes ne sont pas reconstruites correctement car elles ne correspondent pas aux patterns appris pendant l'entraînement.

4.5 Métriques d'évaluation

L'évaluation des modèles repose sur un ensemble de métriques adaptées aux problèmes de détection de fraude, caractérisés par un déséquilibre extrême entre les classes. L'objectif est d'identifier le modèle offrant le meilleur compromis entre rappel, précision et robustesse, tout en tenant compte des contraintes métier propres à l'audit financier.

4.5.1 Choix et justification

Dans un contexte où les transactions frauduleuses représentent moins de 0,15 % du corpus, les métriques classiques comme l'accuracy deviennent peu informatives. Les métriques retenues se concentrent exclusivement sur la capacité du modèle à détecter la classe minoritaire.

Les métriques utilisées sont les suivantes :

- **Précision** : proportion de fraudes parmi les alertes générées.
- **Rappel (Recall)** : proportion de fraudes correctement détectées.
- **F1-score** : moyenne harmonique entre précision et rappel.
- **PR-AUC** : aire sous la courbe Précision–Rappel, métrique la plus pertinente pour les données déséquilibrées.
- **ROC-AUC** : aire sous la courbe ROC, utile mais moins discriminante dans ce contexte.

La PR-AUC est privilégiée car elle ignore les vrais négatifs, très nombreux, et se concentre sur la performance réelle du modèle pour la classe fraude. Cette métrique reflète mieux la capacité du modèle à générer des alertes pertinentes.

4.5.2 Résultats comparatifs sur l'ensemble de test

Le tableau suivant présente les performances finales des modèles sur le jeu de test (39 fraudes parmi 30 001 transactions), en utilisant les seuils optimisés sur l'ensemble de validation.

Les résultats montrent clairement que **XGBoost (XGB_smote)** est le modèle champion, avec un rappel de 84,6 %, une précision de 82,5 % et un F1 de 0,835. Il surpasse l'ensemble des autres modèles, supervisés comme non supervisés.

4.5.3 Analyse des matrices de confusion

La matrice de confusion permet d'interpréter finement les erreurs commises par les modèles, en distinguant les faux positifs (FP) des faux négatifs (FN). Dans un contexte

Modèle	Rappel	Précision	F1	PR-AUC	Seuil
LR_balanced	0.641	0.658	0.649	0.704	0.999
LR_smote	0.692	0.729	0.710	0.739	0.962
RF_balanced	0.769	0.833	0.800	0.779	0.623
RF_smote	0.795	0.816	0.805	0.840	0.629
XGB_smote	0.846	0.825	0.835	0.867	0.355
IsoForest	0.333	0.361	0.347	0.341	0.784
Autoencoder	0.359	0.609	0.451	0.382	1.753
Baseline règle	0.004	1.000	0.008	—	—

TABLE 4.1 – Comparaison des modèles sur le jeu de test

d’audit, ces deux types d’erreurs n’ont pas le même impact : un FN correspond à une fraude non détectée, tandis qu’un FP représente une vérification supplémentaire pour l’auditeur.

La matrice de confusion du modèle champion XGBoost est présentée ci-dessous :

	Prédit : Normal	Prédit : Fraude
Réel : Normal	30 169 (VN)	7 (FP)
Réel : Fraude	6 (FN)	33 (VP)

TABLE 4.2 – Matrice de confusion - XGB_smote (seuil = 0.355)

Cette matrice met en évidence plusieurs points clés :

- **33 fraudes détectées sur 39** : le modèle capture la grande majorité des cas critiques.
- **6 fraudes manquées** : un niveau acceptable compte tenu du déséquilibre extrême.
- **Seulement 7 faux positifs** : charge de travail très faible pour les auditeurs.

Ce comportement confirme que XGBoost offre le meilleur compromis entre rappel et précision, tout en maintenant un volume d’alertes raisonnable.

4.6 Interprétabilité des modèles (XAI)

L’explicabilité constitue un élément central du projet, car les auditeurs doivent pouvoir comprendre et justifier chaque alerte générée par les modèles. La plateforme combine trois niveaux complémentaires d’interprétation : SHAP pour l’analyse globale et locale, LIME pour la génération de règles lisibles, et un module LLM pour la reformulation en langage naturel.

4.6.1 Méthode SHAP

SHAP (SHapley Additive exPlanations) repose sur la théorie des jeux coopératifs et attribue à chaque variable une contribution marginale à la prédiction. Pour un modèle

f et une instance x , la valeur de Shapley associée à la variable j est :

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f_{S \cup \{j\}}(x) - f_S(x)]$$

SHAP présente deux avantages majeurs :

- une **cohérence globale** : les valeurs SHAP moyennes permettent d’identifier les variables les plus influentes ;
- une **explication locale** : pour chaque transaction, SHAP indique quelles variables augmentent ou diminuent le risque.

Dans notre cas, les variables les plus importantes pour XGBoost sont :

1. `balance_diff_orig` - vidage du solde émetteur ;
2. `dest_zero_balance` - compte destinataire à solde nul ;
3. `is_transfer_or_cashout` - type de transaction ;
4. `high_risk_hour` - heures nocturnes ;
5. `log_amount` - montant transformé.

4.6.2 Méthode LIME

LIME (Local Interpretable Model-agnostic Explanations) génère des explications locales en approximent le comportement du modèle autour d’une instance par un modèle linéaire interprétable. LIME cherche un modèle g minimisant :

$$\xi(x) = \arg \min_{g \in G} L(f, g, \pi_x) + \Omega(g)$$

où L mesure la fidélité locale et Ω pénalise la complexité du modèle explicatif.

LIME produit des règles du type :

$$“balance_diff_orig > 5,0 \Rightarrow +0,78”$$

Ces règles sont particulièrement utiles pour les auditeurs, car elles traduisent la décision du modèle en conditions simples et vérifiables.

4.6.3 Comparaison SHAP vs LIME

Les deux méthodes sont complémentaires :

- **SHAP** fournit une explication mathématiquement cohérente, globale et locale, mais parfois difficile à lire pour un non-expert.
- **LIME** génère des règles conditionnelles faciles à interpréter, mais uniquement valables dans le voisinage immédiat de l’instance.

Dans la pratique :

- SHAP identifie les variables dominantes (`balance_diff_orig`, `dest_zero_balance`, etc.);
- LIME reformule ces signaux sous forme de règles lisibles;
- les deux méthodes convergent généralement sur les mêmes indicateurs clés.

4.6.4 Explicabilité par LLM (Groq / Gemini)

Pour rendre l'explication accessible aux auditeurs, les valeurs SHAP et les règles LIME sont transmises à un module LLM (Groq ou Gemini selon disponibilité). Le LLM génère une explication structurée en français, comprenant :

- un **niveau de risque** (Faible, Élevé, Critique);
- un **résumé clair** des anomalies détectées;
- les **raisons principales** (top 3 features anormales);
- des **actions recommandées** pour l'auditeur.

En cas d'indisponibilité du LLM, un **fallback rule-based** génère automatiquement une explication déterministe à partir des valeurs SHAP et des erreurs de reconstruction de l'Autoencoder.

L'intégration conjointe de SHAP, LIME et du LLM garantit une explicabilité complète : mathématique, opérationnelle et compréhensible par les équipes d'audit.

4.7 Sélection du modèle de production

La comparaison approfondie des modèles supervisés et non supervisés a permis d'identifier le classifieur le plus performant pour une mise en production au sein de la plateforme PwC. Parmi l'ensemble des approches évaluées, **XGBoost entraîné sur un corpus équilibré par SMOTE** se distingue nettement.

Ce modèle présente plusieurs avantages déterminants :

- **Meilleur rappel** sur le jeu de test (84,6 %), garantissant la détection de la majorité des fraudes réelles.
- **Précision élevée** (82,5 %), limitant la charge d'investigation liée aux fausses alertes.
- **PR-AUC de 86,7 %**, indiquant une excellente robustesse sur l'ensemble des seuils de décision.
- **Compatibilité native avec SHAP TreeExplainer**, permettant une explicabilité rapide et fiable.
- **Temps d'inférence très faible** (inférieur à la milliseconde par transaction), essentiel pour un usage interactif dans l'interface web.
- **Stabilité du modèle** face au déséquilibre extrême du dataset grâce à l'intégration de SMOTE.

Au regard de ces éléments, **XGB_smote est retenu comme modèle de production**. Il constitue le meilleur compromis entre performance, explicabilité, rapidité et robustesse, tout en répondant aux exigences opérationnelles des équipes d'audit.

4.8 Conclusion du chapitre

Ce chapitre a présenté l'ensemble du processus de modélisation et d'évaluation appliqué à la détection de fraude financière. Après avoir exploré plusieurs familles d'algorithmes - régression logistique, forêts aléatoires, XGBoost, autoencodeur et Isolation Forest - une analyse rigoureuse des métriques a permis d'identifier les forces et limites de chaque approche.

Les modèles supervisés se sont révélés les plus performants, en particulier XGBoost, tandis que les modèles non supervisés conservent un rôle complémentaire pour la détection de schémas inconnus. L'intégration d'un dispositif d'explicabilité multicouche (SHAP, LIME et LLM) garantit une transparence totale des décisions, condition indispensable dans un contexte d'audit.

Les résultats obtenus constituent une base solide pour le déploiement opérationnel du modèle champion et ouvrent la voie au chapitre suivant, consacré à l'architecture technique et à l'intégration du pipeline de détection au sein de la plateforme PwC.

5. Déploiement et architecture technique

5.1 Introduction

La phase de déploiement constitue l'ultime étape du cycle méthodologique CRISP-DM. Elle vise à transformer les modèles développés en un service opérationnel, intégré dans l'écosystème de l'audit financier. L'objectif est de rendre les résultats accessibles via une plateforme web sécurisée, tout en garantissant la robustesse, la scalabilité et la maintenabilité du système. Ce chapitre présente l'architecture technique de la solution, les choix technologiques retenus ainsi que les modes de prédiction mis en œuvre.

5.2 Architecture générale de la plateforme

5.2.1 Vue d'ensemble

La plateforme repose sur une architecture client-serveur moderne et découplée. Elle se compose de trois couches principales :

- **Backend** : une API REST asynchrone développée avec *FastAPI* (Python 3.11), assurant l'orchestration des modèles et la gestion des transactions.
- **Frontend** : une application web monopage construite avec *Next.js 15* (*React 19*), offrant une interface ergonomique et interactive pour les auditeurs.
- **Base de données** : un système *PostgreSQL 16* couplé à l'ORM asynchrone *SQLAlchemy 2.0*, garantissant la persistance des données et la cohérence des opérations.

La communication entre les composants s'effectue via des échanges *JSON* sécurisés sur *HTTPS*, avec un mécanisme d'authentification basé sur des jetons *JWT Bearer*. Cette architecture assure une séparation claire des responsabilités et facilite l'évolution indépendante de chaque module.

5.2.2 Justification des choix technologiques

Les technologies retenues ont été sélectionnées pour répondre aux exigences de performance, de sécurité et de maintenabilité propres au contexte PwC. Le tableau ci-dessous résume les principaux outils et leur justification :

Technologie	Version	Justification
FastAPI	0.115	Framework asynchrone performant, génération automatique de documentation OpenAPI, validation stricte via Pydantic.
SQLAlchemy	2.0	ORM mature avec support natif asynchrone, gestion des migrations via Alembic, forte communauté.
Next.js	15.5	Support du Server-Side Rendering (SSR) et des React Server Components (RSC), optimisations automatiques pour la performance.
TanStack Query	5.62	Gestion avancée du cache côté client, invalidation automatique et mutations optimistes.
XGBoost	2.x	Modèle supervisé champion avec un rappel de 84,6%, inférence rapide en production.
PyTorch	2.x	Framework flexible pour l'AutoEncoder, compatible GPU, adapté aux tâches non supervisées.
fpdf2	2.x	Génération de rapports PDF internes sans dépendances externes, adapté aux livrables PwC.
Prisma	5.22	ORM côté frontend, garantissant la sécurité des types et une intégration fluide avec TypeScript.

TABLE 5.1 – Justification des choix technologiques de la plateforme

5.2.3 Modes de prédiction

La plateforme intègre plusieurs modes de prédiction afin de couvrir différents scénarios d'audit :

- **Supervisé** : modèles tels que *XGBoost* et *Random Forest*, optimisés pour maximiser le rappel et réduire les faux négatifs.
- **Non supervisé** : *AutoEncoder* et *Isolation Forest*, utilisés pour détecter des anomalies dans des contextes où les labels sont absents ou incomplets.
- **Explicabilité** : intégration de *SHAP* et *LIME* pour fournir des explications locales et globales, enrichies par des modules LLM (*Ollama*, *Anthropic*) afin de générer des justifications compréhensibles pour les auditeurs.

Ces modes complémentaires permettent d'assurer une couverture robuste des cas de fraude, tout en offrant une interprétabilité indispensable dans le cadre de l'audit financier.

5.3 Backend FastAPI

5.3.1 Structure des routes et endpoints REST

L'API backend est organisée en plusieurs groupes de routes, chacun dédié à une fonctionnalité spécifique. Cette modularisation facilite la maintenabilité et la séparation des responsabilités. Les principaux modules sont présentés ci-dessous :

Préfixe	Module	Fonctionnalité principale
/api/predict	predict.py	Upload de fichiers CSV et exécution du pipeline de prédiction.
/api/explain	explain.py	Génération d'explications locales et globales via SHAP, LIME et LLM.
/api/report	report.py	Production de rapports PDF/DOCX conformes aux standards PwC.
/api/models	models.py	Consultation des métriques et gestion du registre des modèles.
/api/profile	profile.py	Gestion des utilisateurs et authentification.
/api/audit	audit.py	Journalisation des actions pour assurer la traçabilité.
/api/datasets	datasets.py	Gestion et suivi des jeux de données utilisés.
/api/model-registry	model_registry.py	Versionnement et suivi des modèles déployés.

TABLE 5.2 – Groupes de routes de l'API REST

5.3.2 Pipeline de prédiction asynchrone

Le cœur du backend repose sur l'endpoint `POST /api/predict`, qui accepte un fichier CSV en *multipart/form-data*. Le pipeline de prédiction est exécuté dans un thread séparé grâce à `asyncio.to_thread()`, évitant ainsi de bloquer la boucle d'événements principale.

Le processus suit sept étapes successives :

1. **Profilage des données** : extraction des caractéristiques générales via `DataProfiler`.
2. **Mapping des colonnes** : harmonisation des schémas avec `ColumnMapper`.
3. **Détection du mode** : identification du type de schéma via `SchemaDetector`.
4. **Construction des variables brutes** : génération des features initiales avec `FeatureBuilder`.
5. **Feature engineering** : transformation et enrichissement des variables via `FeatureEngineer`.
6. **Prédiction générique** : inférence des modèles supervisés ou non supervisés via `GenericPredictor`.
7. **Retour de la réponse** : encapsulation des résultats dans `PredictResponse`.

Ce pipeline garantit une exécution robuste et adaptable aux différents formats de données soumis par les auditeurs.

5.3.3 Services principaux

Le backend expose plusieurs services critiques :

- **Service de prédiction** : exécution des modèles supervisés (XGBoost, Random Forest) et non supervisés (AutoEncoder, Isolation Forest).
- **Service d’explication** : génération d’explications locales et globales, enrichies par un module LLM pour une interprétation compréhensible.
- **Service de reporting** : production automatisée de rapports PDF/DOCX intégrant résultats et explications.
- **Service de gestion des modèles** : suivi des versions, métriques et état de disponibilité des modèles déployés.
- **Service d’audit** : journalisation des actions pour assurer la conformité et la traçabilité.

5.3.4 Système de cache LRU et gestion du cycle de vie

Afin d’optimiser les performances, les résultats de prédiction sont mis en cache en mémoire selon une politique **LRU (Least Recently Used)**, limitée à 20 entrées. Ce cache est indexé par `run_id` et partagé entre les routes `/predict` et `/explain`, permettant de réutiliser rapidement les résultats lors de la génération d’explications.

La fonction `lifespan` de FastAPI orchestre le cycle de vie de l’application :

1. Migration automatique de la base de données via Alembic.
2. Chargement en mémoire de tous les modèles ML avec `load_all_models()`.
3. Initialisation du service LLM via `get_llm_helper()`.
4. Création du cache LRU pour les résultats.
5. Exposition d’un endpoint de santé `GET /health`, retournant l’état des modèles, du service LLM et de la base de données.

Ce mécanisme assure un démarrage contrôlé, une disponibilité continue et une surveillance active de l’état du système. ““

5.4 Modèle de données PostgreSQL

5.4.1 Schéma de base de données

La base de données repose sur **PostgreSQL 16**, gérée via l’ORM asynchrone **SQLAlchemy 2.0**. Elle comprend 11 tables principales, organisées de manière à refléter les processus métiers de l’audit et de la détection de fraude.

Les entités essentielles et leurs relations sont les suivantes :

- **User** : représente les utilisateurs de la plateforme. Chaque utilisateur est associé à un rôle (*auditor*, *manager*, *partner*, *admin*) et à un statut (*active*, *inactive*, *suspended*). Les mots de passe sont stockés sous forme hachée avec l'algorithme `bcrypt`.
- **Mission** : correspond aux missions d'audit. Cinq types sont définis (*financial_audit*, *fraud_detection*, *compliance_review*, *risk_assessment*, *internal_audit*), avec quatre statuts possibles. Une mission peut être assignée à plusieurs auditeurs.
- **Dataset** : représente les jeux de données utilisés. Trois catégories sont supportées (*transactions*, *general_ledger*, *trial_balance*), avec cinq statuts de suivi. Les fichiers sont stockés par chemin d'accès.
- **AnalysisRun** : relie un dataset à un modèle et conserve les résultats sous forme de JSON sérialisé.
- **Anomaly** : enregistre les transactions identifiées comme suspectes, avec un niveau de criticité (*CRITIQUE*, *ÉLEVÉ*, *FAIBLE*) et des commentaires associés.
- **PredictionMonitoringLog** : journalise les métriques de surveillance en ligne, telles que le taux de fraude détecté, le montant à risque, la latence d'inférence et les statistiques de variables (`feature_stats` en JSON).
- **ModelVersion** : gère le registre des modèles ML, incluant le versionnement et les métadonnées associées.

La hiérarchie principale peut être représentée ainsi :

`User → Mission → Dataset → AnalysisRun → Anomaly → AnomalyComment`

Cette structure garantit une traçabilité complète des analyses, depuis l'utilisateur jusqu'aux anomalies détectées.

5.4.2 Migrations Alembic

La gestion des évolutions du schéma est assurée par **Alembic**, outil de migration intégré à SQLAlchemy. Les migrations permettent :

- La création initiale des tables et relations.
- L'ajout ou la modification de colonnes sans perte de données.
- Le suivi des versions du schéma grâce à un registre interne.
- L'automatisation des mises à jour lors du démarrage de l'application via la fonction `lifespan`.

Ce mécanisme garantit la cohérence entre le code applicatif et la base de données, tout en facilitant l'évolution progressive du modèle de données au fil des besoins du projet.

5.5 Frontend Next.js 15

5.5.1 Architecture App Router

Le frontend repose sur **Next.js 15** avec l'App Router, permettant une organisation claire des routes par contexte d'authentification. Deux groupes principaux structurent l'application :

- **Route group (auth)** : pages `/login` et `/register`, accessibles sans authentification.
- **Route group (dashboard)** : ensemble des pages protégées par un middleware JWT, réservées aux utilisateurs authentifiés.

Un layout partagé assure la cohérence visuelle et fonctionnelle :

- **Sidebar de navigation** pour accéder aux différentes sections.
- **Header** affichant les informations utilisateur et les options de session.
- **Gestion du thème PwC** (orange/anthracite) pour respecter la charte graphique.

Cette architecture garantit une séparation nette entre les espaces publics et sécurisés, tout en offrant une expérience utilisateur homogène.

5.5.2 Wizard d'analyse en 3 étapes

Le composant `AnalysisWizard.tsx` guide l'auditeur dans un processus en trois étapes séquentielles :

1. **Upload** : sélection d'un dataset existant ou upload d'un nouveau fichier CSV (maximum 500 Mo). Un indicateur de santé des modèles est affiché pour informer l'utilisateur sur leur disponibilité.
2. **Exécution** : suivi du pipeline de prédiction via une barre de progression détaillant chaque étape.
3. **Résultats** : affichage d'un tableau de bord complet (`ResultsDashboard`) présentant les anomalies détectées, les métriques et les explications générées.

Ce wizard simplifie l'expérience utilisateur en rendant le processus d'analyse fluide, progressif et transparent.

5.5.3 Gestion de l'état et des données (Prisma ORM)

La gestion de l'état et des données repose sur plusieurs bibliothèques spécialisées :

- **TanStack Query v5** : gestion de l'état serveur avec cache, invalidation automatique, mutations optimistes et mécanisme de retry exponentiel.
- **Zustand** : gestion de l'état d'authentification, persisté en `sessionStorage`.

- **React Hook Form** + **Zod** : validation des formulaires avec inférence complète des types TypeScript, garantissant robustesse et sécurité des saisies.
- **Prisma ORM** : utilisé côté frontend pour assurer la sécurité des types et une intégration fluide avec la base de données.

Bibliothèques UI

Le frontend intègre plusieurs bibliothèques UI pour améliorer l’ergonomie et la visualisation des résultats :

- **Radix UI** : composants accessibles conformes à la norme WCAG 2.1.
- **Recharts 2.13** : visualisation graphique des résultats (barres, camemberts, courbes).
- **Lucide React 0.468** : iconographie cohérente avec plus de 400 icônes disponibles.
- **Sonner** : notifications toast non bloquantes.
- **Tailwind CSS 3.4** : styles utilitaires et personnalisation du thème PwC.

Cette combinaison de technologies assure une interface moderne, accessible et adaptée aux besoins des auditeurs.

5.6 Sécurité et authentification

5.6.1 Flux d’authentification JWT

Le système d’authentification repose sur des jetons **JWT (JSON Web Token)** afin d’assurer une sécurité robuste et une gestion efficace des sessions. Le flux se déroule comme suit :

1. L’utilisateur soumet ses identifiants via l’endpoint `POST /api/auth/login`.
2. Le backend vérifie le mot de passe haché avec `bcrypt` (salt 10 rounds).
3. Un jeton JWT signé est généré (bibliothèque `jose`, algorithme HS256).
4. Le token est stocké côté client et transmis dans l’en-tête `Authorization: Bearer <token>` à chaque requête.
5. Un middleware FastAPI valide le token et injecte l’utilisateur courant dans le contexte de la requête.

Ce mécanisme garantit une authentification sécurisée et une isolation stricte des sessions.

5.6.2 Contrôle d’accès par rôle (RBAC)

Le contrôle d’accès est implémenté selon le modèle **RBAC (Role-Based Access Control)**. Chaque utilisateur est associé à un rôle déterminant ses permissions. La

matrice suivante résume les droits attribués :

Fonctionnalité	Auditeur	Manager	Partenaire	Admin
Lancer une analyse	✓	✓	✓	✓
Voir les résultats	✓	✓	✓	✓
Générer un rapport	✓	✓	✓	✓
Gérer les missions		✓	✓	✓
Administrer les utilisateurs				✓
Accéder au journal d'audit	✓	✓	✓	

TABLE 5.3 – Matrice d'accès par rôle utilisateur

Ce modèle permet de limiter les privilèges aux seules actions nécessaires, renforçant ainsi la sécurité et la traçabilité des opérations.

5.6.3 Journal d'audit immutable

Toutes les actions sensibles sont enregistrées dans une table `AuditLog`, garantissant un suivi complet et immuable des activités. Le journal couvre 18 types d'actions, incluant :

- `login`
- `dataset.upload`
- `analysis.start`
- `report.generate`
- `user.create`
- etc.

Chaque entrée contient : - L'identité de l'utilisateur. - Son rôle au moment de l'action. - L'horodatage en UTC.

Ce mécanisme assure une traçabilité exhaustive et constitue un élément essentiel pour la conformité réglementaire et la transparence des audits.

5.7 Génération de rapports

5.7.1 Rapport PDF

La génération de rapports constitue une fonctionnalité essentielle de la plateforme, permettant de produire des livrables conformes aux standards PwC. La classe `PwCReport`, développée avec la bibliothèque `fpdf2`, étend les capacités de `FPDF` pour générer des documents professionnels de plus de six pages, intégrant le thème visuel PwC (orange #D04A02 et anthracite #291830).

Le rapport PDF est structuré en plusieurs sections :

1. **Page de couverture** : logo PwC, titre de la mission, date et auditeur responsable.

2. **Résumé exécutif et KPIs** : nombre de transactions analysées, nombre de fraudes détectées, montant total à risque.
3. **Graphiques analytiques** : diagramme en donut des risques, histogrammes par type de transaction, courbes de montants et visualisation SHAP globale.
4. **Top-10 transactions critiques** : tableau détaillé avec scores et indicateurs de risque.
5. **Fiches de cas critiques** : une carte par transaction classée *CRITIQUE*, incluant détails et commentaires.
6. **Recommandations, glossaire et disclaimer** : section finale pour contextualiser les résultats et fournir des pistes d'action.

Ce format garantit une présentation claire, visuelle et directement exploitable par les équipes d'audit.

5.7.2 Rapport Word

En complément du PDF, un générateur alternatif (`report_gen_docx.py`) produit des rapports au format **DOCX**. Ce format est particulièrement utile pour les missions nécessitant des documents modifiables et collaboratifs.

Le rapport Word reprend la même structure que le PDF, mais offre une flexibilité supplémentaire :

- Possibilité d'ajouter ou de modifier des sections par les auditeurs.
- Intégration facilitée dans les outils bureautiques PwC.
- Adaptation rapide aux besoins spécifiques des clients.

Ainsi, la double génération PDF/DOCX permet de répondre à la fois aux exigences de formalisation et aux besoins de personnalisation des missions. “

5.8 Conteneurisation Docker

5.8.1 Structure docker-compose

La plateforme est déployée sous forme de conteneurs Docker afin de garantir la portabilité et la reproductibilité des environnements. Le fichier `docker-compose.yml` définit trois services principaux :

- **PostgreSQL** : base de données persistée via un volume dédié.
- **FastAPI** : backend exposé sur le port 8000, construit à partir du `Dockerfile` racine.
- **Frontend Next.js** : interface utilisateur déployée sur le port 3000, construite à partir du `Dockerfile` situé dans le répertoire `frontend`.

Les services communiquent entre eux via un réseau interne Docker, avec des variables d'environnement centralisées dans le fichier `.env`. Cette structure assure une séparation claire des responsabilités et facilite la maintenance.

5.8.2 Orchestration et reproductibilité

L'orchestration est assurée par `docker-compose`, permettant de démarrer, arrêter et superviser l'ensemble des services en une seule commande. Les principales opérations incluent :

- `docker compose up -build` : construction et démarrage des services.
- `docker compose down` : arrêt et suppression des conteneurs.
- `docker compose logs -f` : suivi en temps réel des journaux.
- `docker compose exec` : exécution de commandes dans un conteneur.

Ce mécanisme garantit la reproductibilité des environnements, évite les problèmes de configuration locale et facilite le déploiement en équipe.

5.9 Tests unitaires et couverture

La qualité logicielle est assurée par une suite de tests unitaires développés avec `pytest`. Les tests couvrent les composants critiques du pipeline et des services backend :

- Pipeline de prédiction : vérification de la cohérence des étapes et gestion des cas limites.
- Explicabilité : validation des sorties SHAP, LIME et LLM.
- Mapping sémantique : détection correcte des colonnes et gestion des conflits.
- Profilage des datasets : contrôle des statistiques et de la qualité des données.
- Modèles ML : vérification des métriques et du statut de mise en production.
- Rapports : génération correcte des fichiers PDF et DOCX.

Un rapport de couverture est produit via `pytest-cov`, générant une synthèse HTML dans `htmlcov/index.html`. Ce suivi permet de mesurer le taux de couverture et d'identifier les zones nécessitant un renforcement des tests.

5.10 Conclusion du chapitre

Le déploiement et l'architecture technique de la plateforme PwC SmartAudit reposent sur une combinaison de technologies modernes et robustes : FastAPI pour le backend, Next.js pour le frontend, PostgreSQL pour la persistance des données et Docker pour la conteneurisation.

Cette architecture modulaire et reproductible garantit :

- Une scalabilité adaptée aux besoins des missions d'audit.

- Une sécurité renforcée grâce à l’authentification JWT, le contrôle d’accès par rôle et le journal d’audit immuable.
- Une traçabilité complète des analyses et des résultats.
- Une intégration fluide des modèles de prédiction et des services d’explicabilité.

Ainsi, la solution déployée constitue un socle technique fiable, évolutif et conforme aux standards PwC, permettant aux équipes d’audit de disposer d’un outil performant et transparent pour la détection de fraude et l’analyse des transactions.

6. Interfaces, résultats et perspectives

6.1 Introduction

Ce chapitre présente les principales interfaces de la plateforme PwC SmartAudit ainsi que les résultats obtenus lors des tests de validation fonctionnelle. Chaque interface est décrite avec ses composants clés, ses interactions prévues et les perspectives qu'elle ouvre pour les équipes d'audit. L'objectif est de démontrer la valeur ajoutée de la solution en termes d'ergonomie, de transparence et de performance.

6.2 Interfaces de la plateforme

6.2.1 Page d'authentification

La page de connexion (`/login`) propose un formulaire épuré aux couleurs PwC.

- Champ email et mot de passe avec validation en temps réel (**Zod**).
- Gestion des erreurs d'authentification via notifications toast (**Sonner**).
- Redirection automatique vers le tableau de bord après connexion réussie.




FIGURE 6.1 – Interface de connexion de la plateforme PwC SmartAudit

6.2.2 Tableau de bord principal

Le tableau de bord (/dashboard) offre une vue synthétique de l'activité de l'auditeur connecté :

- Quatre cartes KPI en temps réel : missions actives, analyses en cours, fraudes détectées ce mois, montant total à risque.
- Graphique d'évolution des détections sur 30 jours (Recharts).
- Liste des missions récentes avec statut coloré et accès rapide.




FIGURE 6.2 – Tableau de bord principal de la plateforme

6.2.3 Gestion des missions d'audit

La page des missions (/missions) permet de :

- Créer une nouvelle mission avec société cliente, type, dates et auditeurs assignés.
- Visualiser toutes les missions sous forme de cartes avec badge de statut coloré.
- Accéder directement à l'assistant d'analyse depuis une mission.





FIGURE 6.3 – Page de gestion des missions d'audit

6.2.4 Wizard d'analyse

Le composant AnalysisWizard guide l'auditeur en trois étapes :

Étape 1 : Sélection des données

Choix d'un dataset existant ou upload d'un nouveau CSV (max 500 Mo).






FIGURE 6.4 – Sélection du jeu de données

Étape 2 : Exécution du pipeline

Barre de progression animée et suivi des étapes.




FIGURE 6.5 – Exécution du pipeline

Étape 3 : Résultats

Affichage des KPIs et résultats du modèle.




FIGURE 6.6 – Tableau de bord des résultats d'analyse

6.2.5 Interface d'explication multicouche

Interface d'explication avec onglets SHAP, AutoEncoder, LIME et LLM.

Tableau de bord des résultats d'analyse

← UHD - MISSION 2026
carrefour - UHD - MISSION 2026

Résultats de l'analyse

- Total transactions: 50
- Anomalies détectées: 10
- Taux de fraude: 20.0%
- Montant à risque: 1645 471 DT
- Modèle utilisé: XGBoost + Autoencoder

mode: standard — Schéma transactionnel complet (9/7 colonnes requises, confiance moy. 100%) → XGBoost + Autoencoder

Graphiques Transactions (50) Rapport

Q Rechercher par ID... Tous les niveaux Toutes Exporter CSV

ID	Type	Montant	Score XGB	Score AE	Risque	Statut
21	CASH_OUT	62 229,21	0.9939	0.6234	Critique	Fraude
48	DEBIT	42 099,27	0.9812	0.7913	Critique	Fraude
41	CASH_OUT	161002,509	0.9389	0.6873	Critique	Fraude
11	CASH_OUT	1468,976	0.9868	0.1285	Critique	Fraude

FIGURE 6.7 – Interface d'explication multicouche d'une transaction suspecte

6.2.6 Génération et téléchargement du rapport

La page /reports permet de générer des rapports PDF ou DOCX.




FIGURE 6.8 – Interface de génération et téléchargement du rapport

6.2.7 Journal d’audit




FIGURE 6.9 – Journal d’audit - traçabilité complète des actions

6.3 Résultats de validation fonctionnelle

6.3.1 Performances sur le jeu de test de référence

Des tests de bout en bout ont été réalisés sur le jeu de test de référence comprenant 30 001 transactions dont 39 fraudes. Les résultats obtenus démontrent la performance et la fiabilité du système :

Métrique	Valeur obtenue	Objectif
Transactions analysées	30 001	-
Fraudes détectées (TP)	33 / 39	31
Rappel	84,6 %	80 %
Précision	82,5 %	70 %
F1-Score	83,5 %	75 %
PR-AUC	86,8 %	80 %
ROC-AUC	99,8 %	95 %
Temps de pipeline (30k tx)	< 15 s	< 30 s
Temps de génération PDF	< 5 s	< 10 s

TABLE 6.1 – Résultats de validation fonctionnelle sur le jeu de test de référence

Ces résultats montrent que le modèle XGBoost avec SMOTE atteint un compromis optimal entre rappel et précision, tout en respectant les contraintes de performance en temps réel.

6.3.2 Robustesse au schéma non standard

Le système de mapping sémantique a été testé sur plusieurs variantes de schémas de données. Les résultats confirment la capacité de la plateforme à s’adapter à des fichiers hétérogènes sans nécessiter de reconfiguration manuelle :

Schéma testé	Niveau atteint	Mode résultant
Colonnes anglaises standard	Exact alias (1,00)	standard (XGB+AE)
Colonnes françaises (<code>montant</code> , <code>type_op</code>)	Signal composé (0,80)	standard
Colonnes abrégées (<code>amt</code> , <code>tx_type</code>)	Fuzzy SequenceMatcher (0,65)	standard
Colonnes partielles (<code>amount</code> seul)	Partiel	ae_isoforest
Schéma inconnu (aucun match)	Aucun	isoforest

TABLE 6.2 – Résultats du mapping sémantique sur schémas non standards

Cette robustesse garantit une compatibilité avec les formats variés des clients, renforçant l’adaptabilité de la solution.

6.3.3 Difficultés rencontrées et solutions apportées

Au cours de la validation, plusieurs difficultés ont été identifiées :

- **Déséquilibre de classes extrême** : le ratio fraude/normal (1 : 774) a entraîné des faux négatifs. L’utilisation de SMOTE et l’optimisation des seuils ont permis d’améliorer le rappel à 84,6 %.
- **Dépendance à certaines variables clés** : la variable `balance_diff_orig` contribue fortement à la détection. En cas d’absence de cette donnée, le système bascule vers un mode non supervisé (IsoForest), moins performant mais toujours fonctionnel.

- **Concept drift temporel** : les patterns de fraude évoluent dans le temps. Une solution envisagée est le ré-entraînement périodique des modèles et la surveillance continue via `PredictionMonitoringLog`.
- **Limitations des modèles non supervisés** : l'AutoEncoder seul atteint un rappel de 35,9 %, confirmant son rôle complémentaire plutôt que substitutif au modèle supervisé.
- **Contraintes architecturales** : le déploiement mono-instance limite la scalabilité. Une orchestration via Kubernetes et l'intégration d'une file de messages (ex. Celery) sont des pistes d'amélioration.

Ces solutions et perspectives renforcent la fiabilité du système et ouvrent la voie à une industrialisation complète de la plateforme.

6.4 Bilan du projet

6.4.1 Objectifs atteints

L'ensemble des objectifs fixés au démarrage du projet a été atteint. Les résultats obtenus démontrent la pertinence des choix méthodologiques et techniques. Le tableau ci-dessous résume les principaux objectifs et leur état de réalisation :

Objectif	Statut	Résultat clé
Rappel 80 %		84,6 % (XGB_smote)
Agnosticisme schéma		4 modes de prédiction
Explicabilité multicouche		SHAP + LIME + LLM
Interface non-technicien		Wizard en 3 étapes
Journal d'audit complet		18 types d'actions tracées
Architecture découplée		FastAPI + Next.js
Rapport PDF professionnel		6+ pages, thème PwC

TABLE 6.3 – Bilan de réalisation des objectifs du projet

Ces résultats confirment que la plateforme répond aux attentes initiales en termes de performance, d'ergonomie et de conformité aux standards PwC.

6.4.2 Contributions techniques

Les contributions techniques majeures de ce projet peuvent être résumées comme suit :

1. **Système de mapping sémantique à 4 niveaux** : permet de traiter des fichiers CSV provenant de différents clients sans nécessiter de ré-entraînement ni de reconfiguration.

2. **Architecture hybride supervisé / non supervisé** : combinaison de XGBoost, AutoEncoder et Isolation Forest, assurant une couverture robuste même en cas de schémas partiels.
3. **Pipeline CRISP-DM automatisé** : de l'upload CSV à la génération du rapport PDF, sans intervention manuelle sur les données.
4. **Explicabilité à 3 niveaux** : intégration successive de SHAP (numérique), LIME (règles conditionnelles) et LLM (explication narrative en français), adaptée à différents profils d'auditeurs.
5. **Surveillance de dérive en ligne** : module `PredictionMonitoringLog` enregistrant taux de fraude, montant à risque et statistiques de variables, permettant une détection précoce du concept drift.

Ces contributions renforcent la valeur ajoutée de la solution en termes de robustesse, d'interprétabilité et d'industrialisation.

6.4.3 Limites identifiées

Malgré les résultats obtenus, certaines limites ont été relevées :

- **Limites du modèle de détection**

- Déséquilibre de classes extrême (ratio 1 :774) entraînant des faux négatifs malgré l'utilisation de SMOTE.
- Forte dépendance à la variable `balance_diff_orig`, dont l'absence dégrade significativement les performances.
- Concept drift temporel nécessitant un ré-entraînement périodique des modèles.
- AutoEncoder seul moins performant (rappel 35,9 % contre 84,6 % pour XGBoost).

- **Limites architecturales**

- Déploiement mono-instance ne permettant pas la scalabilité horizontale.
- Cache LRU limité à 20 entrées, pouvant poser problème en cas d'analyses simultanées.
- Absence de file de messages, les tâches longues étant traitées via `asyncio.to_thread`, ce qui peut saturer le pool de threads.

Ces limites constituent des pistes d'amélioration pour une mise en production à grande échelle, notamment via l'orchestration Kubernetes et l'intégration d'un système de gestion de tâches asynchrones.

6.5 Perspectives d'amélioration

6.5.1 Pipeline MLOps complet

Une évolution naturelle de la plateforme consiste à mettre en place un pipeline **MLOps** complet, permettant un cycle de vie automatisé des modèles.

Les briques envisagées incluent :

- **MLflow** : suivi des expériences, versionnement des artefacts et registre centralisé des modèles.
- **DVC (Data Version Control)** : versionnement des données et reproductibilité des expériences.
- **CI/CD GitHub Actions** : intégration et déploiement continu, avec stratégie blue/green pour éviter les interruptions de service.
- **Surveillance de dérive** : détection automatique des déviations statistiques via tests de Kolmogorov-Smirnov sur les distributions de variables.

Ce pipeline garantirait une mise en production continue et fiable, tout en réduisant le risque lié au concept drift.

6.5.2 Intégration RAG et LLM avancé

L'intégration d'une architecture **RAG (Retrieval-Augmented Generation)** constitue une perspective prometteuse pour enrichir le module d'explicabilité :

- Constitution d'une base de connaissances vectorielle de cas de fraude réels (anonymisés) avec embeddings sémantiques.
- Recherche des cas historiques les plus similaires lors de l'explication d'une transaction suspecte.
- Enrichissement du prompt LLM avec ces précédents pour générer des explications contextualisées et des recommandations plus précises.

Cette approche renforcerait la pertinence des explications fournies aux auditeurs.

6.5.3 Conformité et gouvernance IA

Dans un contexte réglementaire exigeant, la plateforme devra évoluer vers une conformité renforcée :

- **EU AI Act** : classification du système comme IA à haut risque, avec exigences de transparence, d'auditabilité et de supervision humaine.
- **RGPD** : anonymisation systématique des données clients, politique de rétention et implémentation du droit à l'oubli.
- **Intégration GRC** : connexion avec les outils de Governance, Risk & Compliance déjà utilisés chez PwC (Archer, ServiceNow).

Ces évolutions permettront d'aligner la solution avec les standards internationaux de gouvernance et de conformité.

6.5.4 Améliorations métier

Enfin, plusieurs pistes d'amélioration métier peuvent être envisagées :

- Développement de modèles de graphes (**GNN**) pour détecter les fraudes organisées impliquant des réseaux de comptes mules.
- Mise en place d'un apprentissage en ligne (**Online Learning**) pour réduire le concept drift en intégrant progressivement les nouvelles transactions étiquetées.
- Optimisation hyperparamétrique via **Optuna** ou **Ray Tune** pour améliorer les performances des modèles.
- Déploiement multi-instance avec orchestration **Kubernetes** pour assurer la scalabilité horizontale.

Ces améliorations renforceraient la valeur opérationnelle de la plateforme et son adéquation aux besoins des auditeurs.

6.6 Conclusion générale

Ce projet de fin d'études a abouti à la conception et au déploiement d'une plateforme de détection d'anomalies financières fonctionnelle, robuste et documentée. Le modèle champion **XGBoost avec SMOTE** atteint un rappel de 84,6 %, dépassant l'objectif initial de 80 %, tout en maintenant une précision de 82,5 %.

L'architecture technique (**FastAPI + Next.js + PostgreSQL**) garantit la maintenabilité et l'évolutivité de la solution. Le système d'explicabilité multicouche (**SHAP + LIME + LLM**) répond aux exigences de transparence et d'auditabilité imposées par les réglementations telles que l'EU AI Act et les normes ISO 31000.

Les perspectives identifiées - **RAG, MLOps, apprentissage en ligne, modèles de graphes** - constituent une feuille de route concrète pour l'industrialisation future de la solution.

En synthèse, la plateforme PwC SmartAudit démontre qu'il est possible de combiner rigueur scientifique (CRISP-DM, gestion du déséquilibre, évaluation multi-métriques) et valeur métier opérationnelle (interface intuitive, rapports professionnels, explicabilité) dans le cadre d'un projet académique. Ce travail pose les fondations d'un outil d'audit augmenté par l'IA, aligné avec la vision stratégique de PwC de numérisation et d'automatisation des services d'assurance financière.

A. Hyperparamètres détaillés des modèles

A.1 Hyperparamètres complets de la régression logistique

La régression logistique a été configurée avec des hyperparamètres standards, adaptés au contexte de déséquilibre de classes.

Paramètre	Valeur	Justification
solver	liblinear	Adapté aux petits jeux de données et aux classes déséquilibrées.
penalty	l2	Régularisation pour limiter le surapprentissage.
C	1.0	Paramètre de régularisation standard.
class_weight	balanced	Compensation automatique du déséquilibre de classes.
random_state	42	Reproductibilité des résultats.

TABLE A.1 – Hyperparamètres de la régression logistique

A.2 Hyperparamètres complets de la forêt aléatoire

Le modèle Random Forest repose sur un ensemble de 300 arbres de décision, entraînés indépendamment sur des sous-échantillons de données et de variables.

Paramètre	Valeur	Justification
n_estimators	300	Bonne convergence avec temps d'exécution acceptable.
max_depth	10	Limite le surapprentissage tout en capturant la complexité.
min_samples_leaf	5	Feuilles suffisamment peuplées pour éviter les anomalies.
class_weight	balanced	Compensation du déséquilibre de classes.
n_jobs	-1	Parallélisation sur tous les cœurs CPU.
random_state	42	Reproductibilité des résultats.

TABLE A.2 – Hyperparamètres du Random Forest

A.3 Hyperparamètres complets de l’XGBoost

XGBoost a été retenu comme modèle champion grâce à son rappel élevé et sa rapidité d’inférence.

Paramètre	Valeur	Justification
n_estimators	300	Convergence stable du boosting.
max_depth	6	Profondeur modérée pour éviter le sur-apprentissage.
learning_rate	0.05	Faible taux d’apprentissage favorisant la stabilité.
subsample	0.8	Bagging des instances pour réduire la variance.
colsample_bytree	0.8	Bagging des features pour améliorer la généralisation.
scale_pos_weight	774	Ratio négatif/positif pour compenser le déséquilibre.
eval_metric	aucpr	Optimisation directe de la PR-AUC.

TABLE A.3 – Hyperparamètres de XGBoost

Le seuil de décision optimal τ^* a été fixé à 0,355, inférieur au seuil par défaut de 0,5, afin de privilégier le rappel dans un contexte de fraude.

A.4 Hyperparamètres complets de l’autoencodeur

L’autoencodeur est un réseau de neurones profond non supervisé, entraîné uniquement sur les transactions normales. Son objectif est de reconstruire fidèlement les données normales et de produire une erreur élevée sur les fraudes.

Paramètre	Valeur	Justification
Architecture	14-10-7-[4]-7-10-14	Encodeur-décodeur symétrique avec un goulot d'étranglement de 4 dimensions.
Activation	ReLU	Fonction de non-linéarité adaptée aux données tabulaires.
Batch Normalization	Oui	Stabilise et accélère l'apprentissage du réseau.
Dropout	0.2	Réduit le risque de surapprentissage.
Optimiseur	Adam ($\alpha = 10^{-3}$, $\beta_1 = 0.9$, $\beta_2 = 0.999$)	Optimisation adaptative robuste pour les réseaux profonds.
Régularisation L2	10^{-5}	Contrôle la complexité du modèle et améliore la généralisation.
Batch size	256	Compromis entre vitesse d'apprentissage et stabilité des gradients.
Callbacks	EarlyStopping (10 epochs) ReduceLROnPlateau (facteur 0.5)	Ajustement dynamique de l'apprentissage et arrêt anticipé.
Seuil de reconstruction	1.753	Déterminé par recherche sur grille à partir du 99,5 ^e percentile des erreurs de reconstruction des transactions normales.

TABLE A.4 – Hyperparamètres de l'autoencodeur

L'entraînement s'est arrêté à l'époque 36 grâce au mécanisme d'arrêt anticipé (*Early Stopping*), après environ 334 secondes, ce qui confirme la convergence du modèle.

B. Statistiques et entraînement des modèles

B.1 Statistiques descriptives du jeu de données

Le tableau B.1 présente les principales statistiques descriptives des variables numériques du jeu de données utilisé pour l'entraînement et l'évaluation des modèles de détection de fraude.

Variable	Min	Médiane	Moyenne	Max	Std
amount	0	74 871	179 862	9 244 552	603 858
step	1	236	243	743	142
oldbalanceOrg	0	32 099	833 883	59 585 040	2 888 242
balance_diff_orig	-49 300 000	0	-45 761	9 244 552	611 349

TABLE B.1 – Statistiques descriptives des variables numériques (200 000 transactions)

B.2 Évolution de l'entraînement de l'Autoencoder

Le tableau B.2 présente l'évolution de la fonction de perte sur les ensembles d'entraînement et de validation pour plusieurs époques représentatives.

Époque	Loss train	Loss val	Learning Rate
1	0,8412	0,8103	$1,0 \times 10^{-3}$
10	0,2874	0,2821	$1,0 \times 10^{-3}$
20	0,1923	0,1901	$5,0 \times 10^{-4}$
30	0,1769	0,1762	$2,5 \times 10^{-4}$
36	0,1751	0,1751	$1,25 \times 10^{-4}$

TABLE B.2 – Courbe de perte de l'Autoencoder (sélection d'époques, seed = 42)

L'arrêt anticipé (*Early Stopping*) a été déclenché à l'époque 36 avec une patience de 10 époques. Le seuil optimal de reconstruction retenu pour la détection des anomalies est égal à **1,753**.

B.3 Importances des features et corrélations

Le tableau B.3 présente les dix variables les plus importantes selon le modèle Random Forest ainsi que leur corrélation avec la variable cible `isFraud` lorsque celle-ci est disponible.

Feature	Importance RF	Corrélation ρ avec <code>isFraud</code>
<code>balance_diff_orig</code>	37,0 %	0,366
<code>is_transfer_or_cashout</code>	11,7 %	0,041
<code>dest_zero_balance</code>	11,5 %	0,109
<code>log_amount</code>	9,6 %	0,076
<code>hour</code>	7,4 %	—
<code>step</code>	5,5 %	—
<code>type_TRANSFER</code>	4,5 %	—
<code>day</code>	3,9 %	—
<code>high_risk_hour</code>	2,4 %	0,053
<code>type_PAYMENT</code>	2,4 %	—

TABLE B.3 – Top-10 des importances du modèle Random Forest et corrélations avec la cible

L'analyse montre que la variable `balance_diff_orig` constitue de loin le facteur le plus discriminant, représentant à elle seule 37 % de l'importance totale du modèle. Les variables liées au type de transaction et aux caractéristiques des soldes contribuent également de manière significative à la détection des fraudes.

C. Extraits de code source

C.1 Architecture de l'AutoEncoder PyTorch

```
import torch
import torch.nn as nn

class AutoEncoderModel(nn.Module):
    def __init__(self, n_features=14, encoder_dims=[10,7], bottleneck_dim=4, dropout=0.2):
        super().__init__()
        enc_layers = []
        prev = n_features
        for dim in encoder_dims:
            enc_layers += [nn.Linear(prev, dim),
                           nn.BatchNorm1d(dim), nn.ReLU(),
                           nn.Dropout(dropout)]
            prev = dim
        enc_layers.append(nn.Linear(prev, bottleneck_dim))
        self.encoder = nn.Sequential(*enc_layers)

        dec_layers = []
        prev = bottleneck_dim
        for dim in reversed(encoder_dims):
            dec_layers += [nn.Linear(prev, dim),
                           nn.BatchNorm1d(dim), nn.ReLU(),
                           nn.Dropout(dropout)]
            prev = dim
        dec_layers.append(nn.Linear(prev, n_features))
        self.decoder = nn.Sequential(*dec_layers)

    def forward(self, x):
        return self.decoder(self.encoder(x))

    def reconstruction_error(self, x):
        with torch.no_grad():
            return ((x - self.forward(x)) ** 2).mean(dim=1)
```

FIGURE C.1 – Architecture de l'AutoEncoder implémenté avec PyTorch

C.2 Détection automatique du mode de prédiction

```
def detect_schema_mode(mapping_result, df_raw):
    if mapping_result.success:
        return SchemaDetectionResult(
            mode="standard", use_xgb=True,
            use_ae=True, use_isoforest=False,
            reason="Mapping complet --- XGB + AE actifs"
        )
    has_amount = mapping_result.has_amount_col
    n_numeric = len(df_raw.select_dtypes('number').columns)
    if has_amount and n_numeric >= 3:
        return SchemaDetectionResult(
            mode="ae_isoforest", use_xgb=False,
            use_ae=True, use_isoforest=True,
            reason="Mapping partiel --- AE + IsoForest"
        )
    elif has_amount:
        return SchemaDetectionResult(
            mode="ae_only", use_xgb=False,
            use_ae=True, use_isoforest=False
        )
    return SchemaDetectionResult(
        mode="isoforest", use_xgb=False,
        use_ae=False, use_isoforest=True,
        reason="Schema inconnu --- IsoForest transductif"
    )
```

FIGURE C.2 – Détection automatique du mode de prédiction

C.3 Mapping sémantique des colonnes

```
def _match_level(col_name, field):
    norm = col_name.lower().strip().replace(' ', '_')
    # Niveau 1 : alias exact
    if norm in field.exact_aliases:
        return 1.0
    # Niveau 2 : correspondance normalis e
    if norm == field.canonical_name:
        return 0.95
    # Niveau 3 : signaux c o m p o s s
    for signal in field.compound_signals:
        if all(s in norm for s in signal.split('+')):
            return 0.80
    # Niveau 4 : similarite fuzzy SequenceMatcher
    score = SequenceMatcher(None, norm, field.canonical_name).ratio()
    if score >= 0.6:
        return score
    return 0.0

def map_columns(df, fields):
    scores = {}
    for col in df.columns:
        for field in fields:
            s = _match_level(col, field)
            if s > 0:
                scores[(col, field.name)] = s
    # Assignment gloutonn
    assigned = {}
    for (col, fname), s in sorted(scores.items(),
                                   key = lambda x: -x[1]):
        if col not in assigned and fname not in assigned.values():
            assigned[col] = (fname, s)
    return assigned
```

FIGURE C.3 – Exemple de mapping sémantique des colonnes